

Sumário

1 Introdução 1

- 1.1 O que é processamento digital de imagens? 1
- 1.2 As origens do processamento digital de imagens 2
- 1.3 Exemplos de áreas que utilizam o processamento digital de imagens 5
 - 1.3.1 Imagens formadas por raios gama 6
 - 1.3.2 Imagens formadas por raios X 6
 - 1.3.3 Imagens na banda ultravioleta 7
 - 1.3.4 Imagens na banda visível e na banda infravermelha 8
 - 1.3.5 Imagens na banda de micro-ondas 12
 - 1.3.6 Imagens na banda de rádio 12
 - 1.3.7 Exemplos nos quais outras modalidades de imagem são utilizadas 13
- 1.4 Passos fundamentais em processamento digital de imagens 15
- 1.5 Componentes de um sistema de processamento de imagens 18

2 Fundamentos da imagem digital 22

- 2.1 Elementos da percepção visual 22
 - 2.1.1 A estrutura do olho humano 22
 - 2.1.2 Formação da imagem no olho 24
 - 2.1.3 Adaptação ao brilho e discriminação 25
- 2.2 A luz e o espectro eletromagnético 27
- 2.3 Sensores e aquisição de imagens 29
 - 2.3.1 Aquisição de imagens utilizando um único sensor 30
 - 2.3.2 Aquisição de imagens utilizando sensores por varredura de linha 31
 - 2.3.3 Aquisição de imagens utilizando sensores matriciais 32

- 2.3.4 Um modelo simples de formação de imagem 33

2.4 Amostragem e quantização de imagens 34

- 2.4.1 Os conceitos básicos da amostragem e da quantização 34
- 2.4.2 Representação de imagens digitais 35
- 2.4.3 Resolução espacial e de intensidade 38
- 2.4.4 Interpolação de imagens 42

2.5 Alguns relacionamentos básicos entre pixels 44

- 2.5.1 Vizinhos de um pixel 44
- 2.5.2 Adjacência, conectividade, regiões e fronteiras 44
- 2.5.3 Medidas de distância 46

2.6 Uma introdução às ferramentas matemáticas utilizadas no processamento digital de imagens 46

- 2.6.1 Operações de arranjos matriciais *versus* matrizes 47
- 2.6.2 Operações lineares *versus* não lineares 47
- 2.6.3 Operações aritméticas 48
- 2.6.4 Operações com conjuntos e operações lógicas 51
- 2.6.5 Operações espaciais 55
- 2.6.6 Operações com vetores e matrizes 59
- 2.6.7 Transformadas de imagens 60
- 2.6.8 Métodos probabilísticos 62

3 Transformações de intensidade e filtragem espacial 68

3.1 Fundamentos 68

- 3.1.1 Os fundamentos das transformações de intensidade e filtragem espacial 68
- 3.1.2 Sobre os exemplos deste capítulo 70

3.2 Algumas funções básicas de transformação de intensidade 70

- 3.2.1 Negativos de imagem 70
- 3.2.2 Transformações logarítmicas 71
- 3.2.3 Transformações de potência (gama) 71
- 3.2.4 Funções de transformação linear definidas por partes 74
- 3.3 Processamento de histograma 78
 - 3.3.1 Equalização de histograma 79
 - 3.3.2 Especificação de histograma 84
 - 3.3.3 Processamento local de histograma 90
 - 3.3.4 Utilizando estatísticas de histograma para o realce da imagem 91
- 3.4 Fundamentos da filtragem espacial 94
 - 3.4.1 O funcionamento da filtragem espacial 94
 - 3.4.2 Convolução e correlação espacial 96
 - 3.4.3 Representação vetorial da filtragem linear 99
 - 3.4.4 Gerando máscaras de filtragem espacial 99
- 3.5 Filtros espaciais de suavização 100
 - 3.5.1 Filtros lineares de suavização 100
 - 3.5.2 Filtros de estatística de ordem (não lineares) 101
- 3.6 Filtros espaciais de aguçamento 102
 - 3.6.1 Fundamentos 103
 - 3.6.2 Utilizando a segunda derivada para o aguçamento de imagens – o laplaciano 105
 - 3.6.3 Máscara de nitidez e filtragem *high-boost* 107
 - 3.6.4 Utilização de derivadas de primeira ordem para o aguçamento (não linear) de imagens – o gradiente 108
- 3.7 Combinando métodos de realce espacial 110
- 3.8 Utilização de técnicas *fuzzy* para transformações de intensidade e filtragem espacial 112
 - 3.8.1 Introdução 112
 - 3.8.2 Princípios da teoria dos conjuntos *fuzzy* 113
 - 3.8.3 Utilização dos conjuntos *fuzzy* 116
 - 3.8.4 Utilização de conjuntos *fuzzy* para transformações de intensidade 122
 - 3.8.5 Utilização de conjuntos *fuzzy* para filtragem espacial 124

4 Filtragem no domínio da frequência 131

- 4.1 Fundamentos 131
 - 4.1.1 Uma breve história da série e da transformada de Fourier 131
 - 4.1.2 Sobre os exemplos deste capítulo 132
- 4.2 Conceitos preliminares 133
 - 4.2.1 Números complexos 133
 - 4.2.2 Série de Fourier 133
 - 4.2.3 Impulsos e sua propriedade de peneiramento (*sifting*) 133
 - 4.2.4 A transformada de Fourier de funções de uma variável contínua 134
 - 4.2.5 Convolução 137
- 4.3 Amostragem e a transformada de Fourier de funções amostradas 137
 - 4.3.1 Amostragem 138
 - 4.3.2 A transformada de Fourier de funções amostradas 138
 - 4.3.3 O teorema da amostragem 140
 - 4.3.4 *Aliasing* 141
 - 4.3.5 Reconstrução (recuperação) da função a partir dos dados amostrados 143
- 4.4 A transformada discreta de Fourier (DFT) de uma variável 143
 - 4.4.1 Obtenção da DFT a partir da transformada contínua de uma função amostrada 144
 - 4.4.2 Relacionamento entre intervalos de frequência e amostragem 145
- 4.5 Extensão para funções de duas variáveis 146
 - 4.5.1 O impulso 2-D e sua propriedade de peneiramento 146
 - 4.5.2 O par contínuo de transformadas de Fourier 2-D 147
 - 4.5.3 Amostragem bidimensional e teorema da amostragem 2-D 147
 - 4.5.4 *Aliasing* em imagens 148
 - 4.5.5 A transformada discreta de Fourier 2-D e sua inversa 152
- 4.6 Algumas propriedades da transformada discreta de Fourier 2-D 153
 - 4.6.1 Relacionamentos entre intervalos no espaço e na frequência 153
 - 4.6.2 Translação e rotação 153

- 4.6.3 Periodicidade 154
- 4.6.4 Propriedades de simetria 155
- 4.6.5 Espectro de Fourier e ângulo de fase 158
- 4.6.6 O teorema de convolução 2-D 160
- 4.6.7 Resumo das propriedades da transformada discreta de Fourier 2-D 163
- 4.7 Os fundamentos da filtragem no domínio da frequência 166
 - 4.7.1 Características adicionais do domínio da frequência 166
 - 4.7.2 Fundamentos da filtragem do domínio da frequência 167
 - 4.7.3 Resumo dos passos da filtragem no domínio da frequência 171
 - 4.7.4 Correspondência entre a filtragem no domínio do espaço e da frequência 171
- 4.8 Suavização de imagens utilizando filtros no domínio da frequência 175
 - 4.8.1 Filtros passa-baixa ideais 176
 - 4.8.2 Filtros passa-baixa Butterworth 177
 - 4.8.3 Filtros passa-baixa gaussianos 179
 - 4.8.4 Exemplos adicionais de filtragem passa-baixa 181
- 4.9 Aumento de imagens utilizando filtros no domínio da frequência 183
 - 4.9.1 Filtros passa-alta ideais 184
 - 4.9.2 Filtros passa-alta Butterworth 186
 - 4.9.3 Filtros passa-alta gaussianos 186
 - 4.9.4 O laplaciano no domínio da frequência 187
 - 4.9.5 Máscara de nitidez, filtragem *high-boost* e filtragem de ênfase de alta frequência 188
 - 4.9.6 Filtragem homomórfica 190
- 4.10 Filtragem seletiva 192
 - 4.10.1 Filtros rejeita-banda e passa-banda 192
 - 4.10.2 Filtros *notch* 193
 - 4.11.1 Separabilidade da DFT 2-D 196
 - 4.11.2 Cálculo da IDFT utilizando um algoritmo DFT 196
 - 4.11.3 A transformada rápida de Fourier (FFT) 197
 - 4.11.4 Alguns comentários sobre o design de filtros 199
- 5 Restauração e reconstrução de imagens 204**
 - 5.1 Modelo de processo de degradação/restauração de imagens 205
 - 5.2 Modelos de ruído 205
 - 5.2.1 Propriedades espaciais e de frequência do ruído 205
 - 5.2.2 Algumas importantes funções densidade de probabilidade de ruído 206
 - 5.2.3 Ruído periódico 208
 - 5.2.4 Estimativa de parâmetros de ruído 210
 - 5.3 Restauração na presença somente de ruído — filtragem espacial 211
 - 5.3.1 Filtros de média 211
 - 5.3.2 Filtros de estatística de ordem 213
 - 5.3.3 Filtros adaptativos 217
 - 5.4 Redução de ruído periódico pela filtragem no domínio da frequência 220
 - 5.4.1 Filtros rejeita-banda 220
 - 5.4.2 Filtros passa-banda 221
 - 5.4.3 Filtros *notch* 222
 - 5.4.4 Filtragem *notch* ótima 222
 - 5.5 Degradações lineares, invariantes no espaço 225
 - 5.6 Estimativa da função de degradação 227
 - 5.6.1 Estimativa pela observação da imagem 227
 - 5.6.2 Estimativa por experimentação 228
 - 5.6.3 Estimativa por modelamento 228
 - 5.7 Filtragem inversa 230
 - 5.8 Filtragem de mínimo erro quadrático médio (Wiener) 232
 - 5.9 Filtragem por mínimos quadráticos com restrição 235
 - 5.10 Filtro de média geométrica 237
 - 5.11 Reconstrução de imagens a partir de projeções 238

5.11.1	Introdução	238
5.11.2	Princípios da tomografia computadorizada (CT)	240
5.11.3	Projeções e a transformada de Radon*	242
5.11.4	O teorema da fatia de Fourier	246
5.11.5	Reconstrução utilizando retroprojeções filtradas por feixes paralelos	246
5.11.6	Reconstrução utilizando retroprojeções filtradas por feixes em formato de leque	250
6	Processamento de imagens coloridas	259
6.1	Fundamentos das cores	259
6.2	Modelos de cores	264
6.2.1	O modelo RGB de cores	265
6.2.2	Os modelos de cores CMY e CMYK	268
6.2.3	O modelo HSI de cores	268
6.3	Processamento de imagens em pseudocores	274
6.3.1	Fatiamento por intensidades	274
6.3.2	Transformações de intensidade para cores	276
6.4	Fundamentos do processamento de imagens coloridas	280
6.5	Transformações de cores	281
6.5.1	Formulação	281
6.5.2	Complementos de cor	283
6.5.3	Fatiamento de cores	284
6.5.4	Correções de tonalidades e cores	286
6.5.5	Processamento de histogramas	288
6.6	Suavização e aguçamento	290
6.6.1	Suavização de imagens coloridas	291
6.6.2	Aguçamento de imagens coloridas	292
6.7	Segmentação de imagens baseada na cor	292
6.7.1	Segmentação no espaço de cores HSI	292
6.7.2	Segmentação no espaço de vetores RGB	294
6.7.3	Deteção de bordas em imagens coloridas	296
6.8	Ruído em imagens coloridas	298
6.9	Compressão de imagens coloridas	301

7	Processamento com <i>wavelets</i> e multirresolução	306
7.1	Fundamentos	307
7.1.1	Pirâmides de imagem	307
7.1.2	Codificação em sub-bandas	310
7.1.3	A transformada de Haar	315
7.2	Expansões multirresolução	317
7.2.1	Expansões em séries	317
7.2.2	Funções de escala	318
7.2.3	Funções <i>wavelet</i>	321
7.3	Transformadas <i>wavelet</i> em uma dimensão	323
7.3.1	As expansões de séries <i>wavelet</i>	323
7.3.2	A transformada <i>wavelet</i> discreta	324
7.3.3	A transformada <i>wavelet</i> contínua	326
7.4	A transformada rápida de <i>wavelet</i>	327
7.5	Transformadas <i>wavelet</i> em duas dimensões	333
7.6	Pacotes <i>wavelet</i>	338
8	Compressão de imagens	348
8.1	Fundamentos	349
8.1.1	Redundância de codificação	349
8.1.2	Redundância espacial e temporal	351
8.1.3	Informações irrelevantes	351
8.1.4	Medindo as informações da imagem	352
8.1.5	Critérios de fidelidade	354
8.1.6	Modelos de compressão de imagens	355
8.1.7	Padrões de formatos de imagem, contêineres e compressão	356
8.2	Alguns métodos básicos de compressão	358
8.2.1	Codificação de Huffman	358
8.2.2	Codificação de Golomb	360
8.2.3	Codificação aritmética	362
8.2.4	Codificação de LZW	364
8.2.5	Codificação <i>run-length</i>	366
8.2.6	Codificação baseada em símbolos	369
8.2.7	Codificação de planos de bits	372
8.2.8	Codificação por transformada em blocos	374
8.2.9	Codificação preditiva	386
8.2.10	Codificação <i>wavelet</i>	399
8.3	Marca d'água em imagens digitais	405

9 Processamento morfológico de imagens 415

- 9.1 Algumas definições básicas 415
- 9.2 Erosão e dilatação 417
 - 9.2.1 Erosão 417
 - 9.2.2 Dilatação 418
 - 9.2.3 Dualidade 419
- 9.3 Abertura e fechamento 420
- 9.4 A transformada *hit-or-miss* 423
- 9.5 Alguns algoritmos morfológicos básicos 424
 - 9.5.1 Extração de fronteiras 424
 - 9.5.2 Preenchimento de buracos 424
 - 9.5.3 Extração de componentes conexos 425
 - 9.5.4 Fecho convexo 426
 - 9.5.5 Afinamento 428
 - 9.5.6 Espessamento 428
 - 9.5.7 Esqueletos 429
 - 9.5.8 Poda 430
 - 9.5.9 Reconstrução morfológica 433
 - 9.5.10 Resumo das operações morfológicas em imagens binárias 437
- 9.6 Morfologia em imagens em níveis de cinza 437
 - 9.6.1 Erosão e dilatação 440
 - 9.6.2 Abertura e fechamento 441
 - 9.6.3 Alguns algoritmos morfológicos básicos em níveis de cinza 443
 - 9.6.4 Reconstrução morfológica em níveis de cinza 447

10 Segmentação de imagens 454

- 10.1 Fundamentos 455
- 10.2 Detecção de ponto, linha e borda 456
 - 10.2.1 Fundamentos 456
 - 10.2.2 Detecção de pontos isolados 459
 - 10.2.3 Detecção de linhas 462
 - 10.2.4 Modelos de borda 464
 - 10.2.5 Detecção básica de bordas 456
 - 10.2.6 Técnicas mais avançadas para detecção de bordas 470
 - 10.2.7 Ligação de bordas e detecção de fronteiras 478
- 10.3 Limiarização 486
 - 10.3.1 Fundamentos 486

- 10.3.2 Limiarização global simples 488
- 10.3.3 Limiarização global ótima utilizando o método de Otsu 489
- 10.3.4 Usando a suavização da imagem para melhorar a limiarização global 492
- 10.3.5 Usando as bordas para melhorar a limiarização global 494
- 10.3.6 Limiares múltiplos 496
- 10.3.7 Limiarização variável 498
- 10.3.8 Limiarização baseada em diversas variáveis 501

10.4 Segmentação baseada na região 502

- 10.4.1 Crescimento de região 502
- 10.4.2 Divisão e fusão de região 504

10.5 Segmentação usando *watersheds* Morfológicas 506

- 10.5.1 Apresentação 506
- 10.5.2 Construção das barragens 508
- 10.5.3 Algoritmo de segmentação de *watersheds* 509
- 10.5.4 O uso de marcadores 510

10.6 O uso do movimento na segmentação 511

- 10.6.1 Técnicas no domínio do espaço 511
- 10.6.2 Técnicas no domínio da frequência 513

11 Representação e descrição 523

11.1 Representação 523

- 11.1.1 Seguidor de fronteira (contorno) 523
- 11.1.2 Códigos da cadeia 525
- 11.1.3 Aproximações poligonais utilizando polígonos de perímetro mínimo 527
- 11.1.4 Outras abordagens de aproximação poligonal 531
- 11.1.5 Assinaturas 532
- 11.1.6 Segmentos de fronteira 533
- 11.1.7 Esqueletos 535

11.2 Descritores de fronteira 536

- 11.2.1 Alguns descritores simples 537
- 11.2.2 Números do formato 537
- 11.2.3 Descritores de Fourier 538
- 11.2.4 Momentos estatísticos 541

11.3 Descritores regionais 541

- 11.3.1 Alguns descritores simples 541
- 11.3.2 Descritores topológicos 543
- 11.3.3 Textura 545
- 11.3.4 Momentos invariantes 552

11.4 Utilização de componentes principais na descrição 555

11.5 Descritores relacionais 561

12 Reconhecimento de objetos 568

12.1 Padrões e classes de padrões 568

12.2 Reconhecimento com base no método de decisão teórica 570

12.2.1 Casamento *matching* 558

12.2.2 Classificadores estatísticos ótimos 575

12.2.3 Redes neurais 580

12.3 Métodos estruturais 593

12.3.1 Casamento de números de formas 593

12.3.2 Casamento de *Strings* 594

Apêndice A 599

Bibliografia 604

Glossário 614

Índice remissivo 616

Sobre o autor 623




Figura 3.20 Coluna da esquerda: imagens da Figura 3.16. Coluna central: imagens que correspondem aos histogramas equalizados. Coluna da direita: histogramas das imagens da coluna central.

equalizadas fossem visualmente imperceptíveis. Considerando as significativas diferenças de contraste entre as imagens originais, esse exemplo ilustra o poder da equalização de histograma como uma ferramenta adaptável de realce de contraste.

3.3.2 Especificação de histograma

Como sugerido na análise anterior, a equalização de histograma automaticamente determina uma função de

transformação que busca produzir uma imagem de saída que tenha um histograma uniforme. Quando um realce automático é desejado, essa é uma boa abordagem porque os resultados dessa técnica são previsíveis, e sua implementação é fácil. Mostraremos, nesta seção, que há aplicações nas quais o realce baseado em um histograma uniforme não é a melhor metodologia. Em particular, algumas vezes é útil poder especificar o formato do histograma que desejamos que a imagem processada tenha.




Figura 3.21 Funções de transformação para a equalização de histograma. As transformações de (1) a (4) foram obtidas a partir dos histogramas das imagens (de cima para baixo) na coluna esquerda da Figura 3.20 utilizando a Equação 3.3-8.

O método utilizado para gerar uma imagem processada que tenha um histograma específico é chamado de *cassamento de histogramas* ou *especificação de histograma*.

Vamos retomar por um momento as intensidades contínuas r e z (consideradas variáveis aleatórias contínuas), com $p_r(r)$ e $p_z(z)$ expressando suas funções densidade de probabilidade contínua correspondentes. Nessa notação, r e z expressam os níveis de intensidade das imagens de entrada e saída (processada), respectivamente. Podemos estimar $p_r(r)$ a partir da imagem de entrada, ao passo que $p_z(z)$ é a função densidade de probabilidade *especificada* que desejamos que a imagem de saída tenha.

Seja s uma variável aleatória com a propriedade

$$s = T(r) = (L-1) \int_0^r p_r(w) dw \quad (3.3-10)$$

onde, como antes, w é uma variável local de integração. Reconhecemos essa expressão como a versão contínua da equalização de histograma dada na Equação 3.3-4.

Suponha, em seguida, que definamos uma variável aleatória z com a propriedade:

$$G(z) = (L-1) \int_0^z p_z(t) dt = s \quad (3.3-11)$$

onde t é uma variável local de integração. Segue, dessas duas equações, que $G(z) = T(r)$ e, portanto, z deve satisfazer a condição:

$$z = G^{-1}[T(r)] = G^{-1}(s) \quad (3.3-12)$$

A transformação $T(r)$ pode ser obtida com a Equação 3.3-10, uma vez que $p_r(r)$ foi estimada a partir da imagem de entrada. De forma similar, a função de transformação $G(z)$ pode ser obtida utilizando a Equação 3.3-11, já que $p_z(z)$ é dada.

As equações 3.3-10 a 3.3-12 mostram que uma imagem, cujos níveis de intensidade têm uma função densidade de probabilidade especificada, pode ser obtida a partir de uma dada imagem utilizando o seguinte procedimento:

1. Obtenha $p_r(r)$ a partir da imagem de entrada e aplique a Equação 3.3-10 para obter os valores de s .
2. Utilize a PDF especificada na Equação 3.3-11 para obter a função de transformação $G(z)$.
3. Obtenha a transformação inversa $z = G^{-1}(s)$; pelo fato de z ser obtida de s , esse processo é um *mapeamento* de s em z , sendo z os valores desejados.
4. Obtenha a imagem de saída equalizando, inicialmente, a imagem de entrada por meio da Equação 3.3-10; os valores dos pixels dessa imagem são os valores s . Para cada pixel com valor s na imagem equalizada, realize o mapeamento inverso $z = G^{-1}(s)$ para obter o pixel correspondente na imagem de saída. Quando todos os pixels forem processados dessa forma, a PDF da imagem de saída será igual à PDF especificada.

■

Exemplo 3.7 Especificação de histograma.

Considerando valores contínuos de intensidade, suponha que a intensidade de uma imagem tenha uma PDF $p_r(r) = 2r / (L-1)^2$ para $0 \leq r \leq (L-1)$ e $p_r(r) = 0$ para outros valores de r . Encontre a função de transformação que produzirá uma imagem cuja PDF da intensidade seja $p_z(z) = 3z^2 / (L-1)^3$ para $0 \leq z \leq (L-1)$ e $p_z(z) = 0$ para outros valores de z .

Inicialmente, calculamos a transformação de equalização de histograma para o intervalo $[0, L-1]$:

$$\begin{aligned} s = T(r) &= (L-1) \int_0^r p_r(w) dw \\ &= \frac{2}{(L-1)} \int_0^r w dw = \frac{r^2}{(L-1)} \end{aligned}$$

Por definição, essa transformação é 0 para valores fora do intervalo $[0, L-1]$. Elevar ao quadrado os valores das intensidades de entrada e dividi-los por $(L-1)^2$ produzirá uma imagem cujas intensidades, s , têm uma PDF uniforme, porque se trata de uma transformação de equalização de histograma, como discutido anteriormente.

Estamos interessados em uma imagem com um histograma especificado, de forma que calculamos:

$$\begin{aligned} G(z) &= (L-1) \int_0^z p_z(w) dw \\ &= \frac{3}{(L-1)^2} \int_0^z w^2 dw = \frac{z^3}{(L-1)^2} \end{aligned}$$

ao longo do intervalo $[0, L - 1]$; essa função, por definição, é 0 em todos os outros pontos. Por fim, é necessário que $G(z) = s$, mas $G(z) = z^3 / (L - 1)^2$; então $z^3 / (L - 1)^2 = s$, e temos:

$$z = \left[(L - 1)^2 s \right]^{1/3}$$

Assim, se multiplicarmos todo pixel do histograma equalizado por $(L - 1)^2$ e elevarmos o produto à potência $1/3$, o resultado será uma imagem cujas intensidades, z , têm a PDF $p_z(z) = 3z^2 / (L - 1)^3$ no intervalo $[0, L - 1]$, como desejado.

Como $s = r^2 / (L - 1)$, podemos gerar as intensidades, z , diretamente das intensidades, r , da imagem de entrada:

$$z = \left[(L - 1)^2 s \right]^{1/3} = \left[(L - 1)^2 \frac{r^2}{(L - 1)} \right]^{1/3} = \left[(L - 1) r^2 \right]^{1/3}$$

Dessa forma, elevar ao quadrado o valor de cada pixel da imagem original, multiplicar o resultado por $(L - 1)$ e elevar o produto à potência $1/3$ resultará em uma imagem cujos níveis de intensidade, z , têm a PDF especificada. Vemos que o passo intermediário de equalizar a imagem de entrada pode ser pulado; tudo o que precisamos é obter a função de transformação $T(r)$ que mapeia r em s . Então, os dois passos podem ser combinados em uma única transformação de r para z .

Como mostrou o exemplo anterior, a especificação de histograma em princípio é direta. Na prática, uma dificuldade comum é encontrar expressões analíticas significativas para $T(r)$ e G^{-1} . Felizmente, o problema é bastante simplificado quando lidamos com quantidades discretas. O trabalho é o mesmo que na equalização de histograma, na qual somente uma aproximação para o histograma desejado é obtida. Apesar disso, contudo, alguns resultados muito úteis podem ser obtidos, mesmo com aproximações grosseiras.

A fórmula discreta da Equação 3.3-10 é a transformação da equalização de histograma da Equação 3.3-8, que repetiremos aqui por conveniência:

$$s_k = T(r_k) = (L - 1) \sum_{j=0}^k p_r(r_j) = \frac{(L - 1)}{MN} \sum_{j=0}^k n_j \quad (3.3-13)$$

$k = 0, 1, 2, \dots, L - 1$

onde, como antes, MN é o número total de pixels da imagem, n_j é o número de pixels com intensidade r_j e L é o número total de níveis de intensidade possíveis na imagem. De forma similar, dado um valor específico de s_k , a

formulação discreta da Equação 3.3-11 envolve o cálculo da função de transformação:

$$G(z_q) = (L - 1) \sum_{i=0}^q p_z(z_i) \quad (3.3-14)$$

para um valor de q , de forma que:

$$G(z_q) = s_k \quad (3.3-15)$$

sendo $p_z(z_i)$ o i -ésimo valor do histograma especificado. Como antes, calculamos o valor desejado de z_q obtendo a transformação inversa:

$$z_q = G^{-1}(s_k) \quad (3.3-16)$$

Em outras palavras, essa operação nos dá um valor de z para cada valor de s ; assim, ela realiza um *mapeamento* de s em z .

Na prática, não precisamos calcular o inverso de G . Como lidamos com níveis de intensidade que são números inteiros (por exemplo, de 0 a 255 para uma imagem de 8 bits), basta calcular todos os valores possíveis de G utilizando a Equação 3.3-14 para $q = 0, 1, 2, \dots, L - 1$. Esses valores são ajustados e arredondados para os valores inteiros mais próximos cobrindo o intervalo $[0, L - 1]$. Os valores são organizados em uma tabela. Então, dado um determinado valor de s_k , procuramos a melhor correspondência nos valores armazenados na tabela. Se, por exemplo, a 64ª entrada da tabela for a mais próxima de s_k , então $q = 63$ (lembre-se que começamos a contagem a partir de 0), e z_{63} é a melhor solução para a Equação 3.3-15. Dessa forma, o determinado valor s_k seria associado a z_{63} (isto é, aquele valor específico de s_k seria *mapeado* em z_{63}). Como z representa as intensidades utilizadas como base para especificar o histograma $p_z(z)$, segue-se que $z_0 = 0$, $z_1 = 1, \dots, z_{L-1} = L - 1$, de forma que z_{63} teria o valor de intensidade 63. Repetindo esse procedimento, podemos calcular o mapeamento de cada valor de s_k no valor de z_q , que é a solução mais próxima para a Equação 3.3-15. Esses mapeamentos são a solução para o problema de especificação de histograma.

Lembrando que s_k são os valores da imagem do histograma equalizado, podemos resumir o procedimento de especificação de histograma como se segue:

1. Calcule o histograma $p_r(r)$ da imagem em questão e utilize-o para calcular a transformação de equalização de histograma na Equação 3.3-13. Arredonde os valores resultantes, s_k , para o intervalo de números inteiros $[0, L - 1]$.
2. Calcule todos os valores da função de transformação G utilizando a Equação (3.3-14) para $q = 0, 1, 2, \dots, L - 1$, onde $p_z(z_i)$ são os valores do histograma es-

pecificado. Arredonde os valores de G para números inteiros no intervalo $[0, L - 1]$. Anote os valores de G em uma tabela.

3. Para cada valor de $s_k = 0, 1, 2, \dots, L - 1$, utilize os valores de G obtidos no passo 2 para encontrar o valor correspondente de z_q , de forma que $G(z_q)$ seja o mais próximo de s_k e grave esses mapeamentos de s em z . Quando mais de um valor de z_q satisfizer um determinado s_k (isto é, o mapeamento não é único), escolha o menor valor por convenção.
4. Forme a imagem especificada primeiro equalizando o histograma da imagem de entrada e depois mapeando todos os valores dos pixels equalizados, s_k , dessa imagem no valor correspondente z_q na imagem especificada utilizando os mapeamentos do passo 3. Como no caso contínuo, o passo intermediário de equalizar a imagem de entrada é conceitual. Esse passo pode ser pulado combinando as duas funções de transformação, T e G^{-1} , como demonstra o Exemplo 3.8.

Como mencionamos anteriormente, para que G^{-1} satisfaça as condições (a') e (b), G deve ser estritamente monotônica, o que, de acordo com a Equação 3.3-14, significa que nenhum dos valores $p_z(z_i)$ do histograma especificado pode ser zero (Exercício 3.10). Ao trabalhar com quantidades discretas, o fato de essa condição não poder ser satisfeita não representa um problema sério de implementação, como sugere o passo 3. O exemplo a seguir ilustra numericamente esse ponto.

Exemplo 3.8 Um exemplo simples da especificação de histograma.

Vejamos novamente a imagem hipotética 64×64 do Exemplo 3.5, cujo histograma é repetido na Figura 3.22(a). Deseja-se transformar esse histograma de forma que ele tenha os valores especificados na segunda coluna da Tabela 3.2. A Figura 3.22(b) mostra um esboço desse histograma.

O primeiro passo do procedimento é obter os valores ajustados do histograma equalizado, o que fizemos no Exemplo 3.5:

$$\begin{aligned} s_0 &= 1 & s_2 &= 5 & s_4 &= 6 & s_6 &= 7 \\ s_1 &= 3 & s_3 &= 6 & s_5 &= 7 & s_7 &= 7 \end{aligned}$$

No próximo passo, calculamos todos os valores da função de transformação, G , utilizando a Equação 3.3-14:

$$G(z_0) = 7 \sum_{j=0}^0 p_z(z_j) = 0,00$$

De forma similar:

$$G(z_1) = 7 \sum_{j=0}^1 p_z(z_j) = 7[p(z_0) + p(z_1)] = 0,00$$

e

$$\begin{aligned} G(z_2) &= 0,00 & G(z_4) &= 2,45 & G(z_6) &= 5,95 \\ G(z_3) &= 1,05 & G(z_5) &= 4,55 & G(z_7) &= 7,00 \end{aligned}$$

Como no Exemplo 3.5, esses valores fracionários são convertidos em números inteiros no nosso intervalo válido, $[0, 7]$. Os resultados são:

$$\begin{aligned} G(z_0) &= 0,00 \rightarrow 0 & G(z_4) &= 2,45 \rightarrow 2 \\ G(z_1) &= 0,00 \rightarrow 0 & G(z_5) &= 4,55 \rightarrow 5 \\ G(z_2) &= 0,00 \rightarrow 0 & G(z_6) &= 5,95 \rightarrow 6 \\ G(z_3) &= 1,05 \rightarrow 1 & G(z_7) &= 7,00 \rightarrow 7 \end{aligned}$$

Esses resultados são resumidos na Tabela 3.3 e a função de transformação é esboçada na Figura 3.22(c). Observe que G não é estritamente monotônica, de forma que a condição (a') é violada. Assim, utilizamos a abordagem descrita no passo 3 do algoritmo para lidar com essa situação.

No terceiro passo do procedimento, calculamos o menor valor de z_q de modo que o valor $G(z_q)$ seja o mais próximo possível de s_k . Fazemos isso para todos os valores de s_k para criar os mapeamentos necessários de s em z . Por exemplo, $s_0 = 1$, e vemos que $G(z_3) = 1$, o que representa uma associação perfeita nesse caso, de forma que temos a correspondência $s_0 \rightarrow z_3$. Em outras palavras, cada pixel cujo valor é 1 na imagem equalizada do histograma seria mapeado em um pixel com valor igual a 3 (na posição correspondente) na imagem do histograma especificado. Prosseguindo dessa forma, chegamos aos mapeamentos da Tabela 3.4.

No passo final do procedimento, utilizamos os mapeamentos da Tabela 3.4 para mapear cada pixel na imagem do histograma equalizado em um pixel correspondente na imagem do histograma especificado recém-criado. Os valores do




Figura 3.22 (a) Histograma de uma imagem de 3 bits. (b) Histograma especificado desejado. (c) Função de transformação obtida a partir do histograma especificado desejado. (d) Resultado da especificação do histograma. Compare (b) e (d).

Tabela 3.2 Histograma especificado e histograma real (os valores da terceira coluna são provenientes dos cálculos realizados no Exemplo 3.8).

z_q	Especificado $p_z(z_q)$	Real $p_z(z_q)$
$z_0 = 0$	0,00	0,00
$z_1 = 1$	0,00	0,00
$z_2 = 2$	0,00	0,00
$z_3 = 3$	0,15	0,19
$z_4 = 4$	0,20	0,25
$z_5 = 5$	0,30	0,21
$z_6 = 6$	0,20	0,24
$z_7 = 7$	0,15	0,11

histograma resultante são relacionados na terceira coluna da Tabela 3.2, e o histograma é esboçado na Figura 3.22(d). Os valores de $p_z(z_q)$ foram obtidos utilizando o mesmo procedimento do Exemplo 3.5. Por exemplo, vemos na Tabela 3.4 que $s = 1$ é mapeado em $z = 3$, e que há 790 pixels na imagem do histograma equalizado com o valor de 1. Dessa forma, $p_z(z_3) = 790/4.096 = 0,19$.

Apesar de o resultado final mostrado na Figura 3.22(d) não corresponder exatamente ao histograma especificado, a tendência geral de mover as intensidades da imagem para a extremidade superior da escala de intensidade do histograma definitivamente se concretizou. Como mencionamos anteriormente, obter a imagem do histograma equalizado como um passo intermediário é útil para explicar o procedimento, mas não necessário. Em vez disso, poderíamos relacionar os mapeamentos dos valores de r em s e de s em z em uma tabela de três colunas. Então, poderíamos utilizar esses mapeamentos para mapear diretamente os pixels originais nos pixels da imagem do histograma especificado.

Tabela 3.3 Todos os valores possíveis da função de transformação G ajustados, arredondados e ordenados em relação a z .

z_q	$G(z_q)$
$z_0 = 0$	0
$z_1 = 1$	0
$z_2 = 2$	0
$z_3 = 3$	1
$z_4 = 4$	2
$z_5 = 5$	5
$z_6 = 6$	6
$z_7 = 7$	7

Exemplo 3.9 Comparação entre a equalização de histograma e a especificação de histograma.

A Figura 3.23(a) mostra uma imagem da lua de Marte, Fobos, obtida pelo *Mars Global Surveyor*, da Nasa. A Figura 3.23(b) mostra o histograma da Figura 3.23(a). A imagem é dominada por áreas extensas e escuras, resultando em um histograma caracterizado por uma grande concentração de pixels na extremidade mais escura da escala de cinza. À primeira vista, seria possível concluir que a equalização de histograma seria uma boa abordagem para melhorar essa imagem, de forma que os detalhes nas áreas escuras se tornariam mais visíveis. Demonstraremos na análise a seguir que isso não ocorre neste caso.

A Figura 3.24(a) mostra a função de transformação da equalização de histograma (Equação 3.3-8 ou 3.3-13) obtida a partir do histograma da Figura 3.23(b). A característica mais relevante dessa função de transformação é a rapidez na qual ela sobe do nível de intensidade 0 a um nível próximo de 190. Isso é causado pela grande concentração de pixels no histograma de entrada com níveis próximos de 0. Quan-




Figura 3.23 (a) Imagem da lua de Marte, Fobos, obtida pelo *Mars Global Surveyor*, da Nasa. (b) Histograma. (Imagem original: cortesia da Nasa.)

Tabela 3.4 Mapeamentos de todos os valores de s_k nos valores correspondentes de z_q .

s_k	$\rightarrow$	z_q
1	$\rightarrow$	3
3	$\rightarrow$	4
5	$\rightarrow$	5
6	$\rightarrow$	6
7	$\rightarrow$	7

do essa transformação é aplicada aos níveis da imagem de entrada para obter o resultado do histograma equalizado, o efeito final é o mapeamento de um intervalo muito estreito de pixels escuros na extremidade superior da escala de cinza da imagem de saída. Como vários pixels da imagem de entrada apresentam níveis justamente nesse intervalo, esperaríamos que o resultado fosse uma imagem com uma aparência clara e desbotada. Como mostra a Figura 3.24(b), de fato é o que acontece. O histograma dessa imagem é mostrado na Figura 3.24(c). Observe como todos os níveis de intensidade tendem para a metade superior da escala de cinza.

Como o problema com a função de transformação da Figura 3.24(a) foi causado por uma grande concentração de pixels na imagem original com níveis próximos de 0, uma metodologia razoável consiste em modificar o histograma dessa

imagem de forma que ela não apresente essa propriedade. A Figura 3.25(a) mostra uma função *manualmente especificada* que preserva o formato geral do histograma original, mas apresenta uma transição mais suave para os níveis da região escura da escala de cinza. A amostragem dessa função em 256 valores discretos igualmente espaçados produziu o histograma especificado desejado. A função de transformação $G(z)$, obtida a partir desse histograma utilizando a Equação 3.3-14, é indicada como a transformação (1) na Figura 3.25(b). De forma similar, a transformação inversa $G^{-1}(s)$ da Equação 3.3-16 (obtida utilizando o procedimento passo a passo discutido anteriormente) é indicada como a transformação (2) na Figura 3.25(b). A imagem realçada da Figura 3.25(c) foi obtida aplicando a transformação (2) aos pixels da imagem do histograma equalizado na Figura 3.24(b). A melhora na imagem do histograma especificado em relação ao resultado obtido pela equalização de histograma se evidencia na comparação dessas duas imagens. É interessante notar que bastou uma alteração relativamente pequena no histograma original para se obter uma melhora significativa na aparência. A Figura 3.25(d) mostra o histograma da Figura 3.25(c). A característica mais perceptível desse histograma é o fato de que sua extremidade inferior se deslocou para a direita na direção da região mais clara da escala de cinza (mas não excessivamente), como desejado.

Apesar de provavelmente já estar claro, salientamos, antes de concluir esta seção, que a especificação de histo-




Figura 3.24 (a) Função de transformação para a equalização de histograma. (b) Imagem do histograma equalizado (observe a aparência desbotada e sem brilho). (c) Histograma de (b).




Figura 3.25 (a) Histograma especificado desejado. (b) Transformações. (c) Imagem realçada utilizando os mapeamentos da curva (2). (d) Histograma de (c).

grama é, em grande parte, um processo de tentativa e erro. É possível utilizar as orientações aprendidas no exercício em questão, com fizemos no exemplo anterior. Pode haver casos nos quais é possível determinar como um histograma “aproximado” deve parecer e usar isso como o histograma especificado. Em casos como esses, a especificação de histograma passa a ser um processo direto. Em geral, contudo, não há regras para especificar histogramas, e deve-se recorrer à análise caso a caso para qualquer tarefa de realce dada.

3.3.3 Processamento local de histograma

Os métodos de processamento de histograma discutidos nas duas seções anteriores são *globais*, no sentido de que os pixels são modificados por uma função de transformação com base na distribuição de intensidade de toda uma imagem. Apesar de esse método global ser

apropriado para o realce geral da imagem, há casos nos quais é necessário realçar detalhes em pequenas áreas de uma imagem. O número de pixels dessas áreas pode ter uma influência desprezível sobre o cálculo de uma transformação global cujo formato não necessariamente garante o realce local desejado. A solução é elaborar funções de transformação com base na distribuição de intensidade em uma vizinhança de cada pixel da imagem.

As técnicas de processamento de histograma previamente descritas são facilmente adaptadas ao realce local. O procedimento consiste em definir uma vizinhança e mover seu centro de um pixel ao outro. Em cada posição, o histograma dos pontos da vizinhança é calculado e uma função de equalização de histograma ou de especificação de histograma é obtida. Depois disso, essa função é utilizada para mapear a intensidade do pixel central da vizinhança. O centro da região da vizinhança é, então,

movido para a posição do pixel adjacente e o procedimento é repetido. Como apenas uma linha ou coluna da vizinhança muda durante uma translação pixel a pixel da vizinhança, é possível atualizar o histograma obtido na posição anterior com os novos dados em cada passo do movimento (Exercício 3.12). Esse método tem claras vantagens em relação ao cálculo repetido do histograma para todos os pixels da região da vizinhança a cada vez que a região é movida uma posição. Outro método geralmente usado para reduzir os cálculos é o de utilizar regiões que não se sobreponham, mas esse método normalmente produz um efeito “xadrez” não desejado.

Exemplo 3.10 Equalização local de histograma.

A Figura 3.26(a) mostra uma imagem de 8 bits, 512×512 , que à primeira vista parece conter cinco quadrados pretos sobre um fundo cinza. A imagem apresenta um ligeiro ruído, que é imperceptível. A Figura 3.26(b) mostra o resultado da equalização global de histograma. Como costuma ser o caso da equalização de histograma de regiões suaves e com ruído, essa imagem mostra um realce significativo do ruído. Além do ruído, contudo, a Figura 3.26(b) não revela quaisquer novos detalhes relevantes em relação à original, além de uma leve indicação de que o quadrado superior esquerdo e o inferior direito contêm um objeto. A Figura 3.26(c) foi obtida utilizando a equalização local de histograma com uma vizinhança de dimensões 3×3 . No caso, vemos detalhes significativos contidos nos quadrados escuros. Os valores de intensidade desses objetos eram muito próximos da intensidade dos quadrados grandes, e suas dimensões eram pequenas demais para influenciar a equalização global de histograma o suficiente para mostrar esse detalhe.




Figura 3.26 (a) Imagem original. (b) Resultado da equalização global de histograma. (c) Resultado da equalização local de histograma aplicada em (a), utilizando uma vizinhança de dimensões 3×3 .

3.3.4 Utilizando estatísticas de histograma para o realce da imagem

Estatísticas obtidas diretamente do histograma de uma imagem podem ser utilizadas para o realce da imagem. Seja r uma variável aleatória discreta representando os valores de intensidade no intervalo $[0, L - 1]$ e $p(r_i)$ indicando o componente do histograma normalizado correspondente ao valor r_i . Como indicado anteriormente, podemos considerar $p(r_i)$ uma estimativa da probabilidade de a intensidade r_i ocorrer na imagem da qual o histograma foi obtido.

Como discutimos na Seção 2.6.8, o n -ésimo momento de r em relação à sua média é definido como:

$$\mu_n(r) = \sum_{i=0}^{L-1} (r_i - m)^n p(r_i) \quad (3.3-17)$$

onde m é o valor médio (intensidade média) de r (isto é, a intensidade média dos pixels da imagem):*

$$m = \sum_{i=0}^{L-1} r_i p(r_i) \quad (3.3-18)$$

O segundo momento é particularmente importante:

$$\mu_2(r) = \sum_{i=0}^{L-1} (r_i - m)^2 p(r_i) \quad (3.3-19)$$

Reconhecemos essa expressão como a variância da intensidade, normalmente expressa por σ^2 (lembre que o desvio padrão é a raiz quadrada da variância). Enquanto a média é uma medida da intensidade média, a variância (ou desvio padrão) é uma medida do contraste de uma imagem. Observe que todos os momentos são facilmen-

* Seguimos a convenção na utilização de m para o valor médio. Não confunda com o mesmo símbolo utilizado para expressar o número de linhas em uma vizinhança $m \times n$, na qual também utilizamos a convenção notacional.

te calculados utilizando as expressões apresentadas, uma vez que o histograma tenha sido obtido a partir de uma determinada imagem.

Ao trabalhar apenas com a média e a variância, costuma-se estimá-las diretamente dos valores amostrados, sem considerar o histograma. Apropriadamente, essas estimativas são chamadas de *média da amostra* e *variância da amostra*. Elas são dadas pelas expressões a seguir, conhecidas do campo da estatística básica:

$$m = \frac{1}{MN} \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) \quad (3.3-20)$$

e

$$\sigma^2 = \frac{1}{MN} \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} [f(x, y) - m]^2 \quad (3.3-21)$$

para $x = 0, 1, 2, \dots, M-1$ e $y = 0, 1, 2, \dots, N-1$. Em outras palavras, como já sabemos, a intensidade média de uma imagem pode ser obtida pela simples soma dos valores de todos os seus pixels, dividindo a soma pelo número total de pixels na imagem. Uma interpretação similar se aplica à Equação 3.3-21. Como ilustramos no exemplo a seguir, os resultados obtidos utilizando essas duas equações são idênticos aos resultados obtidos utilizando as equações 3.3-18 e 3.3-19, contanto que o histograma utilizado nessas equações seja calculado a partir da mesma imagem utilizada para as equações 3.3-20 e 3.3-21.

Exemplo 3.11 Calculando estatísticas de histograma.

Antes de prosseguir, será útil analisar um simples exemplo numérico para consolidar os conceitos. Considere a imagem a seguir, de 2 bits e tamanho 5×5 :

0	0	1	1	2
1	2	3	0	1
3	3	2	2	0
2	3	1	0	0
1	1	3	2	2

os pixels são representados por 2 bits; dessa forma, $L = 4$ e os níveis de intensidade estão no intervalo $[0, 3]$. O número total de pixels é 25, de forma que o histograma tem os componentes:

$$p(r_0) = \frac{6}{25} = 0,24; \quad p(r_1) = \frac{7}{25} = 0,28;$$

$$p(r_2) = \frac{7}{25} = 0,28; \quad p(r_3) = \frac{5}{25} = 0,20$$

onde o numerador em $p(r_i)$ é o número de pixels na imagem com nível de intensidade r_i . Podemos calcular o valor médio das intensidades da imagem utilizando a Equação 3.3-18:

$$\begin{aligned} m &= \sum_{i=0}^3 r_i p(r_i) \\ &= (0)(0,24) + (1)(0,28) + (2)(0,28) + (3)(0,20) \\ &= 1,44 \end{aligned}$$

Sendo $f(x, y)$ o arranjo matricial anterior 5×5 e utilizando a Equação 3.3-20, obtemos:

$$\begin{aligned} m &= \frac{1}{25} \sum_{x=0}^4 \sum_{y=0}^4 f(x, y) \\ &= 1,44 \end{aligned}$$

Como esperado, os resultados conferem. Do mesmo modo, o resultado para a variância é o mesmo (1,1264) utilizando a Equação 3.3-19 ou a Equação 3.3-21. ■

Consideramos dois usos da média e da variância para fins de realce de imagens. A média e a variância *globais* são calculadas ao longo de toda a imagem e são úteis para ajustes mais gerais em termos de intensidade e contraste. Uma utilização mais poderosa desses parâmetros está no realce local, no qual a média e a variância *locais* são utilizadas como a base para fazer alterações que dependem das características da vizinhança ao redor de cada pixel de uma imagem.

Sejam (x, y) as coordenadas de qualquer pixel de uma determinada imagem e S_{xy} uma vizinhança (subimagem) de tamanho especificado, centrada em (x, y) . O valor médio dos pixels dessa vizinhança é dado pela expressão:

$$m_{S_{xy}} = \sum_{i=0}^{L-1} r_i p_{S_{xy}}(r_i) \quad (3.3-22)$$

onde S_{xy} é o histograma dos pixels na região S_{xy} . Esse histograma tem L componentes, correspondendo aos L valores de intensidade possíveis na imagem de entrada. Contudo, muitos dos componentes são 0, dependendo do tamanho de S_{xy} . Por exemplo, se a vizinhança tiver dimensões 3×3 e $L = 256$, apenas entre 1 e 9 dos 256 componentes do histograma da vizinhança serão diferentes de zero. Esses valores diferentes de zero corresponderão ao número

* O denominador da Equação 3.3-21 algumas vezes é escrito como $MN - 1$ em vez de MN . Isso é feito para obter uma estimativa imparcial da variância. No entanto, estamos mais interessados que as equações 3.3-21 e 3.3-19 se correspondam quando o histograma da Equação 3.3-19 é calculado a partir da mesma imagem utilizada na Equação 3.3-21. Para isso, precisamos do termo MN . A diferença é desprezível para qualquer imagem de dimensões práticas.




Figura 9.32 Limpeza das bordas. (a) Imagem do marcador. (b) Imagem sem objetos tocando a borda. A imagem original é a da Figura 9.29(a).

cena, de modo que somente os objetos completos permanecem para o processamento posterior, ou (2) pode ser utilizado como um sinal de que objetos parciais estão presentes no campo de visão. Como ilustração final dos conceitos introduzidos nesta seção, desenvolvemos um procedimento de limpeza das bordas baseado na reconstrução morfológica. Nesta aplicação, podemos utilizar a imagem original como a máscara e a seguinte imagem como marcador:

$$F(x, y) = \begin{cases} I(x, y) & \text{se } (x, y) \text{ estiver sobre a borda } I \\ 0 & \text{caso contrário} \end{cases} \quad (9.5-30)$$

O algoritmo de limpeza de bordas primeiro calcula a reconstrução morfológica $R_I^D(F)$ (que simplesmente extrai os objetos que tocam a borda da imagem) e, em seguida, calcula a diferença

$$X = I - R_I^D(F) \quad (9.5-31)$$

para obter uma imagem, X , sem objetos tocando a borda.

Como exemplo, considere a imagem do texto novamente. A Figura 9.32(a) mostra a reconstrução $R_I^D(F)$ obtida a partir de um elemento estruturante 3×3 formado de 1s (repare nos objetos que tocam a fronteira do lado direito) e a Figura 9.32(b) mostra a imagem X , calculada usando a Equação 9.5-31. Se a tarefa em questão for o reconhecimento automático de caracteres, ter uma imagem na qual nenhum caractere entra em contato com a borda é mais útil porque o problema de ter de reconhecer caracteres parciais é evitado (uma tarefa difícil no melhor dos casos).

9.5.10 Resumo das operações morfológicas em imagens binárias

A Tabela 9.1 sintetiza os resultados morfológicos desenvolvidos nas seções anteriores, e a Figura 9.33 resume os tipos básicos de elementos estruturantes utilizados nos diversos processos morfológicos discutidos até agora. Os algarismos romanos na terceira coluna da Tabela 9.1 referem-se aos elementos estruturantes na Figura 9.33.

9.6 Morfologia em imagens em níveis de cinza

Nesta seção, estenderemos para imagens em níveis de cinza as operações básicas de dilatação, erosão, abertura e fechamento. Usaremos estas operações para desenvolver vários algoritmos morfológicos básicos para imagens em níveis de cinza.

Ao longo da discussão que se segue, trataremos de funções digitais da forma $f(x, y)$ e $b(x, y)$, em que $f(x, y)$ é uma imagem em níveis de cinza e $b(x, y)$ é um elemento estruturante. Considera-se que essas funções são discretas no sentido introduzido na Seção 2.4.2. Isto é, se Z denota o conjunto de inteiros reais, então as coordenadas (x, y) são inteiros do produto cartesiano Z^2 e f e b são funções que atribuem um valor de intensidade (um número real a partir do conjunto dos números reais, R) para cada par distinto de coordenadas (x, y) . Se os níveis de intensidade também forem inteiros, então Z deve substituir R .

Os elementos estruturantes na morfologia em níveis de cinza executam as mesmas funções básicas que seus equivalentes binários: eles são utilizados como “sondas” para examinar uma determinada imagem procurando suas propriedades específicas. Os elementos estrutu-




Figura 9.33 Cinco tipos básicos de elementos estruturantes utilizados para a morfologia binária. A origem de cada elemento está em seu centro e os $\times$'s indicam os valores “não importa”.

Tabela 9.1 Resumo das operações morfológicas e suas propriedades.

Operação	Equação	Comentários (os algarismos romanos referem-se aos elementos estruturantes na Figura 9.33)
Translação	$(B)_z = \{\omega \omega = b + z, \text{ para } b \in B\}$	Translada a origem de B para o ponto z .
Reflexão	$\hat{B} = \{\omega \omega = -b, \text{ para } b \in B\}$	Reflete todos os elementos de B em torno da origem desse conjunto.
Complemento	$A^c = \{\omega \omega \notin A\}$	Conjunto de pontos que não pertencem a A .
Diferença	$A - B = \{\omega \omega \in A, \omega \notin B\}$ $= A \cap B^c$	Conjunto de pontos que pertencem a A mas não a B .
Dilatação	$A \oplus B = \{z (B)_z \cap A \neq \emptyset\}$	"Expande" a fronteira de A . (I)
Erosão	$A \ominus B = \{z (B)_z \subseteq A\}$	"Contrai" a fronteira de A . (I)
Abertura	$A \circ B = (A \ominus B) \oplus B$	Suaviza os contornos, quebra os istmos e elimina as pequenas ilhas e os picos agudos. (I)
Fechamento	$A \bullet B = (A \oplus B) \ominus B$	Suaviza os contornos, funde pequenas quebras, alonga os golfos finos e elimina pequenos buracos. (I)
Transformada <i>hit-or-miss</i>	$A \otimes B = (A \ominus B_1) \cap (A^c \ominus B_2)$ $= (A \ominus B_1) - (A \oplus B_2)$	Conjunto de pontos (coordenadas) em que, simultaneamente, B_1 encontra um acerto (<i>hit</i>) em A e B_2 encontra um acerto em A^c .
Extração de fronteiras	$\beta(A) = A - (A \ominus B)$	Conjunto de pontos na fronteira do conjunto A . (I)
Preenchimento de buracos	$X_k = (X_{k-1} \oplus B) \cap A^c$; $k = 1, 2, 3, \dots$	Preenche os buracos em A ; X_0 = arranjo matricial de 0s com um 1 em cada buraco. (II)
Componentes conexos	$X_k = (X_{k-1} \oplus B) \cap A$; $k = 1, 2, 3, \dots$	Localiza os componentes conexos em A ; X_0 = arranjo matricial de 0s com um 1 em cada componente conexo. (I)
Fecho convexo	$X_k^i = (X_{k-1}^i \otimes B^i) \cup A$; $i = 1, 2, 3, 4$; $k = 1, 2, 3, \dots$; $X_0^i = A$; e $D^i = X_{\text{conv}}^i$	Localiza o fecho convexo $C(A)$ do conjunto A , no qual "conv" indica convergência no sentido de que $X_k^i = X_{k-1}^i$ (III)
Afinamento	$A \otimes B = A - (A \otimes B)$ $= A \cap (A \otimes B)^c$ $A \otimes \{B\} = ((\dots((A \otimes B^1)$ $\otimes B^2) \dots) \otimes B^n)$ $\{B\} = \{B^1, B^2, B^3, \dots, B^n\}$	Afina o conjunto A . As duas primeiras equações oferecem a definição básica de afinamento. As últimas equações denotam o afinamento por uma sequência de elementos estruturantes. Este método é normalmente utilizado na prática. (IV)
Espessamento	$A \odot B = A \cup (A \otimes B)$ $A \odot \{B\} = ((\dots(A \odot B^1)$ $\odot B^2 \dots) \odot B^n)$	Engrossa o conjunto A . (Veja os comentários anteriores sobre as sequências de elementos estruturantes) Usa IV com 0s e 1s revertido.

(continua)

Tabela 9.1 Resumo das operações morfológicas e suas propriedades. (continuação)

Operação	Equação	Comentários (os algarismos romanos referem-se aos elementos estruturantes na Figura 9.33)
Esqueletos	$S(A) = \bigcup_{k=0}^K S_k(A)$ $S_k(A) = \bigcup_{k=0}^K \{(A \ominus kB) - [(A \ominus kB) \circ B]\}$ Reconstrução de A: $A = \bigcup_{k=0}^K (S_k(A) \oplus kB)$	Localiza o esqueleto $S(A)$ do conjunto A . A última equação indica que A pode ser reconstruído a partir dos subconjuntos de esqueleto $S_k(A)$. Em todas as três equações, K é o valor do passo iterativo após o qual o conjunto A se torna um conjunto vazio. A notação $(A \ominus kB)$ indica a k -ésima iteração de erosões sucessivas de A por B . (I)
Poda	$X_1 = A \otimes \{B\}$ $X_2 = \bigcup_{k=1}^8 (X_1 \otimes B^k)$ $X_3 = (X_2 \oplus H) \cap A$ $X_4 = X_1 \cup X_3$	X_4 é o resultado da poda do conjunto A . O número de vezes que a primeira equação é aplicada para obter X_1 deve ser especificado. Os elementos estruturantes V são utilizados para as duas primeiras equações. Na terceira equação, H refere-se ao elemento estruturante I .
Dilatação geodésica de tamanho 1	$D_G^{(1)}(F) = (F \oplus B) \cap G$	F e G são chamados de imagens do <i>marcador</i> e de <i>máscara</i> , respectivamente.
Dilatação geodésica de tamanho n	$D_G^{(n)}(F) = D_G^{(1)}[D_G^{(n-1)}(F)];$ $D_G^{(0)}(F) = F$	
Erosão geodésica de tamanho 1	$E_G^{(1)}(F) = (F \ominus B) \cup G$	
Erosão geodésica de tamanho n	$E_G^{(n)}(F) = E_G^{(1)}[E_G^{(n-1)}(F)];$ $E_G^{(0)}(F) = F$	
Reconstrução morfológica por dilatação	$R_G^D(F) = D_G^{(k)}(F)$	k é tal que $D_G^{(k)}(F) = D_G^{(k+1)}(F)$
Reconstrução morfológica por erosão	$R_G^E(F) = E_G^{(k)}(F)$	k é tal que $E_G^{(k)}(F) = E_G^{(k+1)}(F)$
Abertura por reconstrução	$O_R^{(n)}(F) = R_F^D[(F \ominus nB)]$	$(F \ominus nB)$ indica n erosões de F por B .
Fechamento por reconstrução	$C_R^{(n)}(F) = R_F^E[(F \oplus nB)]$	$(F \oplus nB)$ indica n dilatações de F por B .
Preenchimento de buracos	$H = [R_{F^c}^D(F)]^c$	H é igual à imagem de entrada I , mas com todos os buracos preenchidos. Veja a Equação 9.5-28 para a definição da imagem do marcador F .
Limpeza das bordas	$X = I - R_I^D(F)$	X é igual à imagem de entrada I , mas todos os objetos que tocam (estão conectados) a borda da imagem são removidos. Veja a Equação 9.5-30 para a definição da imagem do marcador F .

rantes na morfologia em níveis de cinza pertencem a uma dessas duas categorias: *não planos* e *planos*. A Figura 9.34 mostra um exemplo de cada um deles. A Figura 9.34(a) é um ES hemisférico em níveis de cinza mostrado como uma imagem e a Figura 9.34(c) é um perfil de intensida-

de horizontal que passa pelo seu centro. A Figura 9.34(b) mostra um elemento estruturante plano em forma de disco e a Figura 9.34(d) mostra seu perfil de intensidade correspondente (a forma do perfil explica a origem da palavra “plano”). Para melhor entendimento, os elementos




Figura 9.34 Os elementos estruturantes não planos e planos, e os correspondentes perfis de intensidade horizontal que passam através de seu centro. Todos os exemplos apresentados nesta seção baseiam-se em elementos estruturantes planos.

na Figura 9.34 são mostrados como se fossem analógicos (e não discretos), mas sua implementação computacional é baseada em aproximações digitais (por exemplo, veja o ES em forma de disco à direita da Figura 9.2). Em virtude de uma série de dificuldades discutidas mais adiante nesta seção, os ES em níveis de cinza são pouco utilizados na prática. Por último, é bom salientar que, como no caso binário, a origem dos elementos estruturantes deve ser claramente identificada. Salvo indicação contrária, todos os exemplos apresentados nesta seção baseiam-se em elementos estruturantes planos e simétricos de altura unitária cujas origens estão no centro. A *reflexão* de um ES na morfologia em níveis de cinza é definida como vimos na Seção 9.1, e a representaremos na discussão a seguir por $\hat{b}(x, y) = b(-x, -y)$.

9.6.1 Erosão e dilatação

A *erosão* de f por um elemento estruturante *plano* denotado por b em qualquer posição (x, y) é definida como o valor *mínimo* da imagem na região coincidente com b quando a origem de b está em (x, y) . Na forma de uma equação, a erosão em (x, y) de uma imagem f por um elemento estruturante b é dada por

$$[f \ominus b](x, y) = \min_{(s, t) \in b} \{f(x + s, y + t)\} \quad (9.6-1)$$

na qual, de forma semelhante ao processo de correlação discutido na Seção 3.4.2, x e y são incrementados utilizando todos os valores necessários para que a origem de b passe (faça uma varredura) por cada pixel em f . Ou seja, para calcular a erosão de f por b , colocamos a origem do elemento estruturante em todas as posições dos pixels da imagem. A erosão em qualquer posição é

determinada selecionando o valor mínimo de todos os valores de f contidos na região que coincide com b . Por exemplo, se b é um elemento estruturante quadrado de tamanho 3×3 , para obter a erosão de um ponto é necessário encontrar o valor mínimo entre os nove valores de f contidos na região 3×3 definida por b quando sua origem encontra-se nesse ponto.

De forma semelhante, a *dilatação* de f por um elemento estruturante *plano* denotado por b em qualquer posição (x, y) é definida como o valor *máximo* da imagem na região salientada por $\hat{b}$ quando a origem de $\hat{b}$ está em (x, y) . Isto é,

$$[f \oplus b](x, y) = \max_{(s, t) \in b} \{f(x - s, y - t)\} \quad (9.6-2)$$

onde usamos a definição apresentada anteriormente que $\hat{b} = b(-x, -y)$. A explicação dessa equação é idêntica à explicação dada no parágrafo anterior, mas usa a operação de máximo, e não a de mínimo, e considera que o elemento estruturante é refletido em torno de sua origem, o que levamos em conta usando $(-s, -t)$ no argumento da função. Isso é análogo à convolução espacial, como explicada na Seção 3.4.2.

Exemplo 9.9 Ilustração da erosão e dilatação em níveis de cinza.

Como a erosão em níveis de cinza com um ES plano calcula o valor mínimo de intensidade de f em cada vizinhança de (x, y) , coincidente com b , em geral esperamos que uma imagem em níveis de cinza, após a erosão, fique mais escura do que a original e que o tamanho (com relação ao tamanho do ES) dos objetos mais claros sejam reduzidos e o dos objetos mais escuros seja aumentado. A Figura 9.35(b) mostra a erosão da Figura 9.35(a) utilizando um ES em forma de disco de altura unitária e raio de dois pixels. Os efeitos que acabamos de mencionar são claramente visíveis na imagem erodida. Por exemplo, repare como a intensidade dos pequenos pontos claros foi reduzida, fazendo com que eles ficassem pouco visíveis na Figura 9.35(b), enquanto os detalhes mais escuros aumentaram em espessura. O fundo da imagem erodida é ligeiramente mais escuro que o fundo da imagem original. Similarmente, a Figura 9.35(c) mostra o resultado da dilatação com o mesmo ES. Os efeitos são os opostos aos obtidos com a erosão. Os detalhes mais claros ficaram mais espessos e a intensidade dos detalhes escuros foi reduzida. Repare como os conectores finos em preto que aparecem à esquerda, no meio e no canto inferior direito da Figura 9.35(a) são pouco visíveis na Figura 9.35(c). As dimensões dos pontos escuros foram reduzidas em decorrência da dilatação mas, ao contrário dos pequenos pontos brancos erodidos na Figura 9.35(b), eles ainda podem ser vistos com facilidade na imagem dilata- da. A razão é que os pontos pretos eram inicialmente maiores




Figura 9.35 (a) Uma imagem radiográfica em níveis de cinza 448×425 pixels. (b) Erosão usando um disco plano com um raio de 2 pixels. (c) Dilatação usando o mesmo ES. (Imagem original cortesia da Lixi, Inc.)

que os pontos brancos no que diz respeito ao tamanho do ES. Finalmente, observe que o fundo da imagem dilatada é ligeiramente mais claro do que o da Figura 9.35(a).

Os ES não planos têm valores em níveis de cinza que variam ao longo de seu domínio de definição. A erosão da imagem f pelo elemento estruturante não plano b_N , é definida como

$$[f \ominus b_N](x, y) = \min_{(s, t) \in b_N} \{f(x + s, y + t) - b_N(s, t)\} \quad (9.6-3)$$

Aqui, na verdade subtraímos valores de f para determinar a erosão em qualquer ponto. Isso significa que, ao contrário da Equação 9.6-1, a erosão com um ES não plano não está delimitada em geral pelos valores de f , o que pode apresentar problemas na interpretação dos resultados. Os elementos estruturantes em níveis de cinza raramente são usados na prática em virtude disso, sem falar das possíveis dificuldades ao selecionar elementos significativos para b_N e do custo computacional adicional quando comparado com a Equação 9.6-1.

De maneira similar, a dilatação que usa um ES não plano é definida como

$$[f \oplus b_N](x, y) = \max_{(s, t) \in b_N} \{f(x - s, y - t) + b_N(s, t)\} \quad (9.6-4)$$

As observações feitas no parágrafo anterior são aplicáveis à dilatação com os elementos estruturantes não planos. Quando todos os elementos de b_N são constantes (isto é, o ES é plano), as equações 9.6-3 e 9.6-4 se reduzem às equações 9.6-1 e 9.6-2, respectivamente, dentro de um escalar constante igual à amplitude do ES.

Como no caso binário, a erosão e a dilatação são duais em relação ao complemento e à reflexão da função, isto é,

$$(f \ominus b)^c(x, y) = (f^c \oplus \hat{b})(x, y)$$

sendo $f^c = -f(x, y)$ e $\hat{b} = b(-x, -y)$. A mesma expressão vale para os elementos estruturantes não planos. Exceto quando necessitamos de maior clareza, podemos simplificar a notação na discussão a seguir omitindo os argumentos de todas as funções, no caso em que a equação precedente será escrita como

$$(f \ominus b)^c = (f^c \oplus \hat{b}) \quad (9.6-5)$$

Similarmente

$$(f \oplus b)^c = (f^c \ominus \hat{b}) \quad (9.6-6)$$

A erosão e a dilatação, por si sós, não são particularmente úteis no processamento de imagens em níveis de cinza. Tal como acontece nos seus equivalentes binários, as operações tornam-se poderosas quando utilizadas em combinação para obter algoritmos de mais alto nível, como demonstra o material das seções a seguir.

9.6.2 Abertura e fechamento

As expressões para abertura e fechamento de imagens em níveis de cinza têm a mesma forma que seus correspondentes binários. A *abertura* da imagem f pelo elemento estruturante b , indicada por $f \circ b$, é*

$$f \circ b = (f \ominus b) \oplus b \quad (9.6-7)$$

Como antes, a abertura é simplesmente a erosão de f por b , seguida por uma dilatação do resultado com b . Da mesma forma, o *fechamento* de f por b , indicado por $f \bullet b$, é

$$f \bullet b = (f \oplus b) \ominus b \quad (9.6-8)$$

A abertura e o fechamento de imagens em níveis de cinza são duais em relação ao complemento e à reflexão do ES:

* Apesar de lidarmos com elementos estruturantes planos nos exemplos do restante desta seção, os conceitos discutidos são igualmente aplicáveis aos elementos estruturantes não planos.

$$(f \cdot b)^c = f^c \circ \hat{b} \quad (9.6-9)$$

e

$$(f \circ b)^c = f^c \cdot \hat{b} \quad (9.6-10)$$

Como $f^c = -f(x, y)$, a Equação 9.6-9 também pode ser escrita como $-(f \cdot b) = (-f \cdot \hat{b})$. O mesmo ocorre para a Equação 9.6-10.

A abertura e o fechamento de imagens possuem uma interpretação geométrica simples. Suponha que uma função de imagem $f(x, y)$ seja vista como uma superfície 3-D, isto é, seus valores de intensidade sejam interpretados como os valores da altura sobre o plano xy , como na Figura 2.18(a). Então, a abertura de f por b pode ser interpretada geometricamente como se empurrássemos o elemento estruturante de baixo para cima contra a superfície inferior de f . Em cada posição da origem de b , a abertura é o valor mais alto alcançado por qualquer parte de b , uma vez que se choca com a superfície inferior de f . A abertura completa é, então, o conjunto de todos esses valores obtidos ao fazer que a origem de b passe por cada uma das coordenadas (x, y) de f .

A Figura 9.36 ilustra o conceito em uma dimensão.* Suponha que a curva na Figura 9.36(a) seja o perfil de intensidade ao longo de uma única linha de uma




Figura 9.36 Abertura e fechamento em uma dimensão. (a) Sinal original 1-D. (b) Elemento estruturante plano sob o sinal empurrado de baixo para cima. (c) Abertura. (d) Elemento estruturante plano sobre o sinal empurrado de cima para baixo. (e) Fechamento.

* Às vezes, a abertura e o fechamento são ilustrados como o processo de rolar um círculo na superfície superior e inferior de uma curva. Em 3-D, o círculo se torna uma esfera, e os procedimentos resultantes são chamados de algoritmos de *bola rolante*.

imagem. A Figura 9.36(b) mostra um elemento estruturante plano em várias posições, empurrando para cima contra a superfície inferior da curva. A curva sólida na Figura 9.36(c) é a abertura completa. Uma vez que o elemento estruturante é muito grande para caber completamente dentro dos picos mais estreitos da curva, os topos desses picos foram cortados pela operação morfológica de abertura e a quantidade retirada é proporcional à altura que o elemento estruturante foi capaz de alcançar no interior desse pico. Em geral, as aberturas são usadas para remover pequenos detalhes claros, enquanto não alteram os níveis de cinza globais nem os grandes elementos claros.

A Figura 9.36(d) é uma ilustração gráfica do fechamento. Observe que o elemento estruturante é empurrado para baixo à medida que percorre o topo da curva em todas as localizações. O fechamento, na Figura 9.36(e), é determinado encontrando os pontos mais baixos atingidos por qualquer parte do elemento estruturante conforme este desliza pelo lado superior da curva.

A operação de abertura dos níveis de cinza possui as seguintes propriedades:

- (a) $f \circ b \leq f$
- (b) se $f_1 \leq f_2$, então $(f_1 \circ b) \leq (f_2 \circ b)$
- (c) $(f \circ b) \circ b = f \circ b$

A notação $e \leq r$ é usada para indicar que o domínio de e é um subconjunto do domínio de r , e também que $e(x, y) \leq r(x, y)$ para qualquer (x, y) no domínio de e .

Da mesma forma, a operação de fechamento possui as seguintes propriedades:

- (a) $f \leq f \cdot b$
- (b) se $f_1 \leq f_2$, então $(f_1 \cdot b) \leq (f_2 \cdot b)$
- (c) $(f \cdot b) \cdot b = f \cdot b$

A utilidade dessas propriedades é semelhante àquela dos seus correspondentes binários.

Exemplo 9.10 Ilustração da abertura e fechamento em níveis de cinza.

A Figura 9.37 estende a 2-D os conceitos 1-D ilustrados na Figura 9.36. A Figura 9.37(a) é a mesma imagem que utilizamos no Exemplo 9.9, e a Figura 9.37(b) é a abertura obtida usando um elemento estruturante em forma de disco de altura unitária e raio de 3 pixels. Como esperado, a intensidade de todos os objetos claros na imagem diminuiu, dependendo de seus tamanhos em relação ao tamanho do ES. Comparando essa figura com a Figura 9.35(b), vemos que, ao contrário do resultado da erosão, a abertura teve um efeito imperceptível nos objetos escuros da imagem, e o




Figura 9.37 (a) Imagem radiográfica em níveis de cinza de tamanho 448×425 pixels. (b) Abertura usando um ES em forma de disco com um raio de 3 pixels. (c) Fechamento usando um ES de raio 5.

efeito sobre o fundo foi insignificante. Similarmente, a Figura 9.37(c) mostra o fechamento da imagem com um disco de raio 5 (os pequenos pontos pretos são maiores que os pequenos pontos brancos, então é necessário um disco maior para obter resultados comparáveis aos da abertura). Nesta imagem, os objetos claros e o fundo foram muito pouco afetados, mas os objetos escuros foram atenuados, sendo que o grau de atenuação depende do tamanho relativo dos objetos em relação ao ES.

9.6.3 Alguns algoritmos morfológicos básicos em níveis de cinza

Inúmeras técnicas morfológicas estão baseadas nos conceitos de morfologia em níveis de cinza introduzidos até o momento. Ilustraremos alguns desses algoritmos na discussão seguinte.

Suavização morfológica

Como a abertura suprime detalhes claros menores que o ES especificado, e o fechamento suprime os detalhes escuros, eles são comumente usados em conjunto, como *filtros morfológicos* para a suavização de imagens e remoção de ruídos. Considere a Figura 9.38(a), que mostra uma imagem da supernova *Cygnus Loop* adquirida na banda de raios X (ver Figura 1.7 para mais detalhes sobre esta imagem). Para fins da presente discussão, suponha que a região central clara é o objeto de interesse, e que os componentes menores são ruídos. O objetivo é eliminar o ruído. A Figura 9.38(b) mostra o resultado da abertura da imagem original com um disco plano de raio 1 e, em seguida, o fechamento da abertura com um ES do mesmo tamanho. As figuras 9.38(c) e (d) mostram os resultados da mesma operação utilizando discos de raios 3 e 5, respectivamente. Como esperado, esta sequência mostra a remoção progressiva dos pequenos componentes em função do tamanho do ES. No último resultado, vemos que o objeto de interesse foi extraído. Os componentes de ruído na parte inferior da imagem

não puderam ser removidos completamente por causa de sua densidade.

Os resultados mostrados na Figura 9.38 basearam-se na abertura da imagem original e, em seguida, no fechamento da abertura. Um procedimento utilizado algumas vezes é a *filtragem sequencial alternada*, em que sequência de abertura-fechamento começa com a imagem original, mas os passos subsequentes executam a abertura e o fechamento sobre as imagens resultantes das etapas anteriores. Este tipo de filtragem é útil na análise automatizada de imagens, em que os resultados em cada etapa são comparados utilizando uma métrica especificada. Geralmente, essa abordagem produz mais borramento para o mesmo tamanho de ES utilizado para o método ilustrado na Figura 9.38.




Figura 9.38 (a) Imagem de 566×566 da supernova *Cygnus Loop*, adquirida na banda de raios X pelo telescópio Hubble da Nasa. (b) a (d) Resultados da realização da sequência abertura-fechamento na imagem original, com elementos estruturantes no forma de disco de raios 1, 3 e 5, respectivamente. (Imagem original: cortesia da Nasa.)

Gradiente morfológico

A dilatação e a erosão podem ser usadas em conjunto com a subtração de imagens para obter o gradiente morfológico da imagem, conhecido como g , em que*

$$g = (f \oplus b) - (f \ominus b) \quad (9.6-11)$$

A dilatação engrossa regiões na imagem, e a erosão as afina. A diferença entre esses resultados ressalta as fronteiras entre regiões. As áreas homogêneas não são afetadas (desde que o ES seja relativamente pequeno) e, por isso, a operação de subtração tende a eliminá-las. O resultado final é uma imagem cujas bordas são realçadas, e a contribuição das áreas homogêneas é atenuada, produzindo um efeito semelhante ao dos filtros derivativos (gradiente).

A Figura 9.39 mostra um exemplo. A Figura 9.39(a) é uma tomografia computadorizada do crânio, e as próximas duas figuras são a abertura e o fechamento com um ES de 3×3 e todos 1s. Repare o espessamento e a redução mencionadas anteriormente. A Figura 9.39(d) é o gradiente morfológico obtido usando a Equação 9.6-11, em que as fronteiras entre as regiões estão claramente delineadas, como era de esperar de uma imagem derivativa 2-D.




Figura 9.39 (a) Imagem 512×512 de uma tomografia computadorizada da cabeça. (b) Dilatação. (c) Erosão. (d) Gradiente morfológico, calculado como a diferença entre (b) e (c). (Imagem original: cortesia do Dr. David R. Pickens, Universidade de Vanderbilt.)

* Consulte a Seção 3.6.4 para uma definição do gradiente de uma imagem.

Transformadas *top-hat* e *bottom-hat*

Combinando a subtração de imagens com aberturas e fechamentos se produz o que conhecemos como transformadas *top-hat* e *bottom-hat*. A transformada *top-hat* de uma imagem em níveis de cinza f é definida como f menos sua abertura:

$$T_{\text{hat}}(f) = f - (f \circ b) \quad (9.6-12)$$

Da mesma forma, a transformada *bottom-hat* de f é definida como o fechamento de f menos f :

$$B_{\text{hat}}(f) = (f \bullet b) - f \quad (9.6-13)$$

Uma das principais aplicações dessas transformadas está na remoção de objetos de uma imagem usando um elemento estruturante na operação de abertura ou de fechamento que não se encaixa nos objetos a serem removidos. A operação de diferença produz então uma imagem na qual apenas os componentes removidos permanecem. A transformada *top-hat* é usada para objetos claros sobre um fundo escuro, e a transformada *bottom-hat* é usada para o objetivo contrário. Por essa razão, os nomes *top-hat branco* e *top-hat preto*, respectivamente, são usados com frequência quando se fala dessas duas transformadas.

Um uso importante das transformadas *top-hat* é na correção dos efeitos da iluminação não uniforme. Como veremos no capítulo seguinte, a iluminação adequada (uniforme) desempenha um papel fundamental no processo de extração de objetos do fundo da imagem. Esse processo, chamado *segmentação*, é um dos primeiros passos realizados na análise automatizada de imagens. Uma metodologia usada frequentemente na segmentação é a limiarização da imagem de entrada.

Para ilustrar, veja a Figura 9.40(a), que mostra uma imagem 600×600 de grãos de arroz. Essa imagem foi obtida em condições de iluminação não uniforme, como evidenciado pela área mais escura na parte inferior direita da imagem. A Figura 9.40(b) mostra o resultado da limiarização pelo método de Otsu, um método ótimo de limiarização que será discutido na Seção 10.3.3. O resultado da iluminação não uniforme causou erros de segmentação na área escura (vários grãos de arroz não foram extraídos do fundo), bem como na parte superior esquerda da imagem, onde partes do fundo foram erroneamente segmentadas. A Figura 9.40(c) mostra a abertura da imagem com um disco de raio 40. Este ES era grande o suficiente para não caber dentro de nenhum dos objetos. Como resultado, os objetos foram eliminados deixando apenas




Figura 9.40 Usando a transformada *top-hat* para a correção de sombreamento. (a) Imagem original de tamanho 600×600 pixels. (b) Imagem após a limiarização. (c) Imagem aberta usando um ES em forma de disco de raio 40. (d) Transformada *top-hat* (a imagem menos a sua abertura). (e) Imagem *top-hat* após a limiarização.

uma aproximação do fundo. O padrão de sombreamento é evidente nessa imagem. Subtraindo essa imagem da original (isto é, realizando uma transformada *top-hat*), o fundo deveria ficar mais uniforme. Isso foi o que ocorreu de fato, como mostra a Figura 9.40(d). O fundo não ficou perfeitamente uniforme, mas as diferenças entre os extremos claros e escuros tornaram-se menores e isso foi o suficiente para produzir um resultado correto de segmentação em que todos os grãos de arroz foram detectados, como mostra a Figura 9.40(e). Essa imagem foi obtida pelo método de Otsu, como a anterior.

Granulometria

Em termos de processamento de imagem, a *granulometria* é um campo que lida com a determinação da distribuição de tamanhos de partículas em uma imagem. Na prática, as partículas quase nunca estão separadas claramente, o que faz da contagem de partículas pela identificação individual uma tarefa difícil. A morfologia pode ser usada para estimar a distribuição do tamanho das partículas indiretamente, sem a necessidade de identificar e medir cada partícula na imagem.

A abordagem em princípio é simples. Com partículas de formato regular, que são mais claras que o fundo, o método consiste na aplicação de aberturas com elementos estruturantes de tamanho crescente. A ideia básica é que as operações de abertura de tamanhos específicos

devem ter maior efeito sobre as regiões da imagem de entrada que contenha partículas de tamanho semelhante. Para cada abertura, a soma dos valores de pixel na abertura é calculada. Essa soma, chamada às vezes de *área de superfície*, diminui conforme se aumenta o tamanho do ES, já que, como vimos anteriormente, as aberturas reduzem a intensidade dos elementos claros. Esse procedimento produz um arranjo matricial 1-D desses números, e cada elemento do arranjo é igual à soma dos pixels na abertura para o tamanho do ES correspondente a essa posição no arranjo. Para salientar as mudanças entre as aberturas sucessivas, calculamos a diferença entre os elementos adjacentes do arranjo matricial 1-D. Para visualizar os resultados, as diferenças são exibidas graficamente. Os picos no gráfico são um indicativo das distribuições de tamanho predominante das partículas na imagem.

Por exemplo, considere a Figura 9.41(a), que é uma imagem de pinos de madeira de dois tamanhos dominantes diferentes. Os grãos de madeira nos pinos podem introduzir variações nas aberturas, por isso a suavização é uma etapa importante de pré-processamento nesse caso. A Figura 9.41(b) mostra a imagem suavizada usando o filtro de suavização morfológico discutido anteriormente, com um disco de raio 5. As figuras 9.41(c) a (f) mostram exemplos de aberturas de imagem com discos de raios 10, 20, 25 e 30. Repare, na Figura 9.41(d), que a contribuição de intensidade devida aos pinos pequenos foi




Figura 9.41 (a) Imagem de tamanho 531×675 de pinos de madeira. (b) Imagem suavizada. (c) a (f) Aberturas de (b) com discos de raios iguais a 10, 20, 25 e 30 pixels, respectivamente. (Imagem original: cortesia do Dr. Steve Eddins, The MathWorks, Inc.)

praticamente eliminada. Na Figura 9.41(e), a contribuição dos pinos grandes foi significativamente reduzida e, na Figura 9.41(f), mais ainda. (Observe na Figura 9.41(e) que o pino grande na parte superior direita da imagem é muito mais escuro do que os outros em razão de seu tamanho menor. Essa informação seria útil se estivéssemos tentando detectar pinos com defeitos).

A Figura 9.42 mostra um gráfico do arranjo de diferenças. Como mencionado anteriormente, esperamos diferenças significativas (picos no gráfico) em torno dos raios em que o ES é grande o suficiente para abranger um conjunto de partículas com aproximadamente o mesmo diâmetro. O resultado na Figura 9.42 tem dois picos distintos, indicando claramente a presença de dois tamanhos de objetos dominantes na imagem.

Segmentação de texturas

A Figura 9.43(a) mostra uma imagem ruidosa de bolhas escuras sobrepostas sobre um fundo claro. A ima-




Figura 9.42 Diferenças na área de superfície em função do raio do disco do ES, r . Os dois picos são indicativos de dois tamanhos de partículas dominantes na imagem.

gem tem duas regiões de textura: uma região composta de bolhas grandes à direita e uma região à esquerda composta por bolhas menores. O objetivo é encontrar uma fronteira entre as duas regiões com base em seu conteúdo de textura (discutiremos a textura na Seção 11.3.3). Como observado anteriormente, o processo de subdividir uma imagem em regiões é chamado de *segmentação*, que é o tema do Capítulo 10.

Os objetos de interesse são mais escuros do que o fundo, e sabemos que, se fecharmos a imagem com um elemento estruturante maior do que as bolhas menores, elas




Figura 9.43 Segmentação de texturas. (a) Uma imagem 600×600 que consiste de dois tipos de bolhas. (b) Imagem com pequenas bolhas removidas pelo fechamento de (a). (c) Imagem cujos espaços claros entre as grandes bolhas foram removidos efetuando a abertura de (b). (d) Imagem original com a fronteira entre as duas regiões em (c) sobrepostas. A fronteira foi obtida por uma operação de gradiente morfológico.

serão removidas. O resultado na Figura 9.43(b), obtido pelo fechamento da imagem de entrada usando um disco com um raio de 30 pixels, mostra que, na verdade, isso é o que acontece (o raio das bolhas é de aproximadamente 25 pixels). Portanto, neste momento, temos uma imagem com grandes bolhas escuras sobre um fundo claro. Se *abrirmos* esta imagem com um elemento estruturante que seja grande em relação à separação entre essas bolhas, o resultado final deve ser uma imagem em que os espaços claros entre as bolhas foram removidos, deixando as bolhas e os espaços entre elas igualmente escuros. A Figura 9.43(c) mostra o resultado obtido usando um disco de raio 60.

Realizando um gradiente morfológico sobre essa imagem com, digamos, um ES de 3×3 de 1s, obteremos a fronteira entre as duas regiões. A Figura 9.43(d) mostra a fronteira obtida a partir da operação de gradiente morfológico sobreposto na imagem original. Todos os pixels à direita da fronteira pertencem à região de textura caracterizada pelas bolhas grandes, e o oposto para os pixels à esquerda da fronteira. Para entender esse exemplo com mais detalhes, utilize a analogia gráfica para abertura e fechamento, ilustrada na Figura 9.36.

9.6.4 Reconstrução morfológica em níveis de cinza

A reconstrução morfológica em níveis de cinza é definida basicamente da mesma forma que na Seção 9.5.9 para imagens binárias. Considere que f e g sejam o *marcador* e a *máscara*, respectivamente. Supomos que ambas são imagens em níveis de cinza do mesmo tamanho e que $f \leq g$. A *dilatação geodésica* de tamanho 1 de f com relação a g é definida como*

$$D_g^{(1)}(f) = (f \oplus b) \wedge g \quad (9.6-14)$$

onde $\wedge$ denota o operador mínimo pontual. Essa equação indica que a dilatação geodésica de tamanho 1 é obtida calculando primeiro a dilatação de f por b e, depois, selecionando o mínimo entre o resultado e g em cada ponto (x, y) . A dilatação é dada pela Equação 9.6-2, se b for um ES plano, ou pela Equação 9.6-4, se ele não for. A dilatação geodésica de tamanho n de f em relação a g é definida como

$$D_g^{(n)}(f) = D_g^{(1)}[D_g^{(n-1)}(f)] \quad (9.6-15)$$

com $D_g^{(0)}(f) = f$

Da mesma forma, a *erosão geodésica* de tamanho 1 de f em relação a g é definida como

$$E_g^{(1)}(f) = (f \ominus b) \vee g \quad (9.6-16)$$

* Entende-se que essas expressões são funções de (x, y) . Omitimos as coordenadas para simplificar a notação.

onde $\vee$ denota o operador máximo pontual. A erosão geodésica de tamanho n é definida como**

$$E_g^{(n)}(f) = E_g^{(1)}[E_g^{(n-1)}(f)] \quad (9.6-17)$$

com $E_g^{(0)}(f) = f$.

A *reconstrução morfológica por dilatação* de uma imagem de máscara em níveis de cinza, g , por uma imagem de marcador em níveis de cinza, f , é definida como a dilatação geodésica de f em relação a g , que sofreu iterações até a estabilidade ser atingida, ou seja,

$$R_g^D(f) = D_g^{(k)}(f) \quad (9.6-18)$$

com k de forma que $D_g^{(k)}(f) = D_g^{(k+1)}(f)$. A *reconstrução morfológica por erosão* de g por f é igualmente definida como

$$R_g^E(f) = E_g^{(k)}(f) \quad (9.6-19)$$

com k de forma que $E_g^{(k)}(f) = E_g^{(k+1)}(f)$.

Como no caso binário, a abertura por reconstrução de imagens em níveis de cinza primeiro efetua a erosão na imagem de entrada e depois a usa como marcador. A *abertura por reconstrução* de tamanho n de uma imagem f é definida como a reconstrução por dilatação de f a partir da erosão de tamanho n de f , isto é,

$$O_R^{(n)}(f) = R_f^D[(f \ominus nb)] \quad (9.6-20)$$

em que $(f \ominus nb)$ denota n erosões de f por b , como explicado na Seção 9.5.7. Lembremos da discussão da Equação 9.5-27 para imagens binárias, cujo objetivo da abertura por reconstrução era preservar o formato dos componentes da imagem que permaneceram após a erosão.

Similarmente, o *fechamento por reconstrução* de tamanho n de uma imagem f é definido como a reconstrução por erosão de f a partir da dilatação de tamanho n de f , isto é,

$$C_R^{(n)}(f) = R_f^E[(f \oplus nb)] \quad (9.6-21)$$

na qual $(f \oplus nb)$ denota n dilatações de f por b . Por causa da dualidade, o fechamento por reconstrução de uma imagem pode ser obtido complementando a imagem, obtendo a abertura por reconstrução e complementando o resultado. Finalmente, como mostra o exemplo a seguir, uma técnica útil, chamada *top-hat por reconstrução*, consiste em subtrair de uma imagem a sua abertura por reconstrução.

** Veja o Exercício 9.33 para uma lista de relações duais entre as expressões mostradas nessa seção.

Exemplo 9.11 Utilizando a reconstrução morfológica para uniformizar um fundo complexo.

Neste exemplo, ilustraremos o uso da reconstrução em níveis de cinza em vários passos para normalizar o fundo irregular da imagem na Figura 9.44(a), deixando apenas o texto em um fundo de intensidade constante. A solução deste problema é um bom exemplo do poder dos conceitos de morfologia. Começamos eliminando o reflexo horizontal na parte superior das teclas. Os reflexos são maiores do que qualquer um dos caracteres na imagem; por isso, devemos ser capazes de eliminá-los realizando uma abertura por reconstrução usando uma longa linha horizontal na operação de erosão. Essa operação vai produzir um fundo contendo as teclas e seus reflexos. Subtraindo isso da imagem original (ou seja, realizando um *top-hat* por reconstrução), eliminamos os reflexos horizontais e as variações no fundo da imagem original.

A Figura 9.44(b) mostra o resultado da abertura por reconstrução da imagem original usando uma linha horizontal de tamanho 1×71 pixels na operação de erosão. Poderíamos

ter usado apenas uma abertura para remover os caracteres, mas o fundo resultante não teria sido tão uniforme como mostra a Figura 9.44(c) (por exemplo, compare as regiões entre as teclas em ambas as imagens). A Figura 9.44(d) mostra o resultado da subtração da Figura 9.44(b) da Figura 9.44(a). Como esperado, os reflexos horizontais e as variações do fundo foram suprimidos. Para efeito de comparação, a Figura 9.44(e) mostra o resultado de realizar apenas a transformação *top-hat* (ou seja, subtraindo a abertura “padrão” da imagem, como discutido anteriormente nesta seção). Como era esperado a partir das características do fundo da Figura 9.44(c), o fundo da Figura 9.44(e) não é tão uniforme quanto na Figura 9.44(d).

O próximo passo é eliminar os reflexos verticais das bordas das teclas, que são bastante visíveis na Figura 9.44(d). Podemos fazer isso realizando uma abertura por reconstrução com um ES de formato de linha cuja amplitude é quase igual aos reflexos (aproximadamente 11 pixels neste caso). A Figura 9.44(f) mostra o resultado de executar essa operação na Figura 9.44(d). Os reflexos verticais foram elimina-




Figura 9.44 (a) Imagem original de tamanho 1.134×1.360 pixels. (b) Abertura por reconstrução de (a) usando uma linha horizontal de 71 pixels de comprimento na erosão. (c) Abertura de (a) utilizando a mesma linha. (d) *Top-hat* por reconstrução. (e) *Top-hat*. (f) Abertura por reconstrução de (d) usando uma linha horizontal de 11 pixels de comprimento. (g) Dilatação de (f) usando uma linha horizontal de 21 pixels de comprimento. (h) Mínimo de (d) e (g). (i) Resultado final da reconstrução. (Imagem original: cortesia do Dr. Steve Eddins, The MathWorks, Inc.)

dos, mas também foram suprimidos os elementos verticais finos que são caracteres válidos (por exemplo, o I em SIN), então temos de encontrar uma maneira de restaurar este último. Os caracteres eliminados estão muito perto de outros caracteres; então, se dilatarmos os caracteres restantes na horizontal, os caracteres dilatados vão se sobrepor na área ocupada anteriormente pelos caracteres eliminados. A Figura 9.44(g), obtida dilatando a Figura 9.44(f), com um ES de linha de tamanho 1×21 , mostra que realmente era este o caso.

Tudo o que resta neste momento é recuperar os caracteres eliminados. Considere uma imagem formada como o mínimo pontual entre a imagem dilatada na Figura 9.44(g) e a imagem do *top-hat* por reconstrução da Figura 9.44(d). A Figura 9.44(h) mostra a imagem mínima (embora este resultado pareça estar perto de nosso objetivo, repare que o I em SIN ainda está faltando). Usando essa imagem como um marcador e a imagem dilatada como a máscara de reconstrução em níveis de cinza (Equação 9.6-18), obtemos o resultado final na Figura 9.44(i). Essa imagem mostra que todos os caracteres foram devidamente extraídos do fundo original e irregular, incluindo o fundo das teclas. O fundo da Figura 9.44(i) é totalmente uniforme.

Resumo

Os conceitos e as técnicas morfológicas apresentados neste capítulo constituem um poderoso conjunto de ferramentas para a extração de características de interesse em uma imagem. Um dos aspectos mais atraentes do processamento morfológico de imagens é o fundamento teórico extenso a partir do qual as técnicas morfológicas evoluíram. Uma vantagem significativa em termos de implementação computacional consiste no fato de a dilatação e a erosão serem operações primitivas que são a base para uma ampla classe de algoritmos morfológicos. Como mostrará o próximo capítulo, a morfologia pode ser usada como base para o desenvolvimento de procedimentos de segmentação de imagens com inúmeras aplicações. Conforme será discutido no Capítulo 11, as técnicas morfológicas também desempenham um papel importante nos processos de descrição da imagem.

Referências e leitura complementar

O livro de Serra (1982) é uma referência fundamental no processamento morfológico de imagens. Veja também Serra (1988), Giardina e Dougherty (1988) e Haralick e Shapiro (1992). Referências básicas adicionais relevantes para nossa discussão incluem Blum (1967), Lantuéjoul (1980), Maragos (1987) e Haralick et al. (1987). Para uma visão geral da morfologia tanto binária quanto


das escalas de cinza, veja Basart e Gonzalez (1992) e Basart et al. (1992). Este conjunto de referências oferece uma base ampla para o material abordado nas seções 9.1 a 9.4. Para uma boa visão geral do material das seções 9.5 e 9.6, ver o livro de Soille (2003).

Questões importantes da implementação de algoritmos morfológicos, como os indicados nas seções 9.5 e 9.6, são exemplificadas nos trabalhos de Jones e Svalbe (1994), Park e Chin (1995), Sussner e Ritter (1997), Anelli et al. (1998) e Shaked e Bruckstein (1998). Um artigo de Vincent (1993) é especialmente importante em termos de detalhes práticos para a implementação de algoritmos morfológicos em níveis de cinza. Veja também o livro de Gonzalez, Woods, e Eddins (2004).

Para uma leitura adicional sobre a teoria e as aplicações de processamento morfológico de imagens, veja o livro de Goutsias e Bloomberg (2000) e uma edição especial da *Pattern Recognition* (2000). Veja também uma compilação de referências de Rosenfeld (2000). Os livros de Marchand-Maillet e Sharaiha (2000), sobre o processamento de imagens binárias, e de Ritter e Wilson (2001) sobre a álgebra da imagem também são de interesse. Os trabalhos atuais sobre a aplicação de técnicas morfológicas para processamento de imagem aparece nos artigos escritos por Kim (2005) e Evans e Liu (2006).

Exercícios*

- 9.1 As imagens digitais neste livro encontram-se dentro de uma grade quadrada, e os pixels podem ser 4, 8, ou m -conectados. No entanto, outras modalidades de grade também são possíveis. Especificamente, uma grade hexagonal que leva à conectividade-6 é usada por vezes (veja a figura a seguir).
 - (a) Como você converteria uma imagem de uma grade quadrada em uma grade hexagonal?
 - (b) Discuta sobre a invariância de forma na rotação de objetos representados em uma grade quadrada em oposição a uma grade hexagonal.
 - (c) É possível ter configurações ambíguas diagonais em uma grade hexagonal, como ocorre com a conectividade-8? (ver Seção 2.5.2).



* Soluções detalhadas dos exercícios marcados com um asterisco podem ser encontradas no site do livro. O site também contém sugestões de projetos baseados no material neste capítulo.

9.2 * (a) Desenvolva um algoritmo morfológico para converter uma fronteira binária 8-conectada em uma fronteira m -conectada (ver Seção 2.5.2). Você pode assumir que a fronteira está totalmente conectada e que possui espessura de um pixel.

(b) O funcionamento de seu algoritmo exige mais do que uma iteração com cada elemento estruturante? Explique.

(c) O desempenho de seu algoritmo é independente da ordem em que os elementos estruturantes são aplicados? Se sua resposta for afirmativa, demonstre. Senão, mostre um exemplo que ilustre a dependência de seu procedimento na ordem da aplicação dos elementos estruturantes.

9.3 A erosão de um conjunto A pelo elemento estruturante B é um subconjunto de A sempre que a origem de B esteja contida em A . Dê um exemplo em que a erosão $A \ominus B$ esteja fora, ou parcialmente fora, de A .

9.4 As quatro afirmações seguintes são verdadeiras. Proponha um argumento que estabeleça o(s) motivo(s) das suas validades. A parte (a) em geral é verdadeira. As partes (b) até (d) são verdadeiras apenas para os conjuntos *digitais*. Para mostrar a validade de (b) até (d), desenhe uma grade discreta e quadrada (como mostrado no Exercício 9.1) e ofereça um exemplo para cada caso utilizando conjuntos compostos por pontos nesta grade. (*Dica*: mantenha o número de pontos em cada caso o mais baixo possível até estabelecer a validade das declarações.)


*** (a)** A erosão de um conjunto convexo por um elemento estruturante convexo é um conjunto convexo.

*** (b)** A dilatação de um conjunto convexo por um elemento estruturante convexo não é necessariamente sempre convexo.

(c) Os pontos em um conjunto convexo digital nem sempre estão conectados.

(d) É possível ter um conjunto de pontos em que a linha que une cada dupla de pontos no conjunto esteja dentro do conjunto sem que o conjunto seja convexo.

***9.5** Com referência à imagem mostrada, encontre o elemento estruturante e a(s) operação(ões) morfológica(s) que produziu(ram) cada um dos resultados mostrados nas imagens (a) até (d). Mostre claramente a origem de cada elemento estruturante. As linhas tracejadas mostram a fronteira do conjunto original e foram incluídas apenas para referência. Repare que em (d) todos os cantos são arredondados.




9.6 Considere que A seja o conjunto sombreado mostrado na figura a seguir. Utilize os elementos estruturantes exibidos (os pontos pretos mostram a origem). Esboce o resultado das seguintes operações morfológicas:

(a) $(A \ominus B^4) \oplus B^2$

(b) $(A \ominus B^1) \oplus B^3$

(c) $(A \oplus B^1) \oplus B^3$

(d) $(A \oplus B^3) \ominus B^2$



- *9.7** (a) Qual é o efeito limitante de dilatar repetidamente uma imagem? Suponha que um elemento estruturante trivial (um ponto) não seja utilizado.
- (b) Qual é a menor imagem a partir da qual você pode começar para que sua resposta na parte (a) permaneça válida?
- 9.8** (a) Qual é o efeito limitante de erodir repetidamente uma imagem? Suponha que um elemento estruturante trivial (um ponto) não seja utilizado.
- (b) Qual é a menor imagem a partir da qual você pode começar para que sua resposta na parte (a) permaneça válida?
- *9.9** Uma definição alternativa da erosão é

$$A \ominus B = \{\omega \in Z^2 | \omega + b \in A, \text{ para todos } b \in B\}$$

Mostre que essa definição é equivalente à definição da Equação 9.2-1.

- 9.10** (a) Mostre que a definição de erosão dada no Exercício 9.9 é equivalente à outra definição de erosão:

$$A \ominus B = \bigcap_{b \in B} (A)_{-b}$$

(Se $-b$ é substituída por b , esta expressão é chamada de *subtração de Minkowsky* de dois conjuntos.)

- (b) Mostre que a expressão em (a) é equivalente também à definição da Equação 9.2-1.

- *9.11** Uma definição alternativa de dilatação é

$$A \oplus B = \{\omega \in Z^2 | \omega = a + b, \text{ para } a \in A \text{ e } b \in B\}$$

Mostre que essa definição e a definição na Equação 9.2-3 são equivalentes.

- 9.12** (a) Mostre que a definição de dilatação dada no Exercício 9.11 é equivalente à outra definição de dilatação:

$$A \oplus B = \bigcup_{b \in B} (A)_b$$

(Esta expressão também é chamada de *soma de Minkowsky* de dois conjuntos.)

- (b) Mostre que a expressão em (a) também é equivalente à definição da Equação 9.2-3.

- 9.13** Prove a validade da expressão de dualidade na Equação 9.2-6.

- *9.14** Prove a validade da expressão de dualidade

$$(A \bullet B)^c = (A^c \circ \hat{B}) \text{ e } (A \circ B)^c = (A^c \bullet \hat{B})$$

- 9.15** Prove a validade das expressões a seguir:

*** (a)** $A \bullet B$ é um subconjunto (subimagem) de A .

- (b) Se C é um subconjunto de D , então $C \bullet B$ é um subconjunto de $D \bullet B$.

(c) $(A \bullet B) \bullet B = A \bullet B$.

- 9.16** Demonstre a validade das seguintes expressões (assuma-se que a origem de B está contida em B e que os exercícios 9.14 e 9.15 são verdadeiros):

- (a) A é um subconjunto (subimagem) de $A \bullet B$.


- (b) Se C é um subconjunto de D , então $C \bullet B$ é um subconjunto de $D \bullet B$.

(c) $(A \bullet B) \bullet B = A \bullet B$.


- 9.17** Considere a imagem e o elemento estruturante mostrados. Esboce como devem ficar os conjuntos C , D , E e F na seguinte sequência de operações: $C = A \ominus B$; $D = C \oplus B$; $E = D \oplus B$; e $F = E \ominus B$. O conjunto inicial A consiste de todos os componentes da imagem mostrados em branco, com exceção do elemento estruturante B . Repare que essa sequência de operações é simplesmente a abertura de A por B , seguida do fechamento dessa abertura por B . Você pode assumir que B é grande o suficiente para incluir cada um dos componentes distorcidos.




- *9.18** Considere as três imagens binárias mostradas na figura a seguir. A imagem à esquerda está composta por quadrados com lados de tamanhos 1, 3, 5, 7, 9 e 15 pixels. A imagem no meio foi gerada pela erosão da imagem da esquerda com um elemento estruturante quadrado de 1s, de tamanho 13×13 pixels, com o objetivo de eliminar todos os quadrados, exceto os maiores. Finalmente, a imagem da direita é o resultado da dilatação da imagem no centro com o mesmo elemento estruturante, com o objetivo de restaurar os quadrados maiores. Você sabe que a erosão seguida da dilatação é a abertura de uma imagem, e sabe também que a abertura geralmente não restaura os objetos à sua forma original. Explique porque a reconstrução total dos quadrados grandes foi possível neste caso.



- 9.19** Esboce o resultado da aplicação da transformada *hit-or-miss* à imagem e ao elemento estruturante mostrado. Indique claramente a origem e a borda que você selecionou para o elemento estruturante.



- *9.20** Três características (lago, baía e segmento de linha) úteis para diferenciar os objetos afinados na imagem são mostradas na figura a seguir. Desenvolva um algoritmo lógico/morfológico de diferenciação entre essas formas. A entrada para o algoritmo seria uma dessas três formas. A saída deve ser a identidade da entrada. Você pode assumir que as características são de 1 pixel de espessura e que estão totalmente conectadas entre si. No entanto, podem aparecer em qualquer orientação.



- 9.21** Discuta que resultado você esperaria em cada um dos seguintes casos:

- O ponto de partida do algoritmo de preenchimento de buracos da Seção 9.5.2 é um ponto na fronteira do objeto.
- O ponto de partida no algoritmo de preenchimento de buracos está fora da fronteira.
- Esboce como ficaria o fecho convexo da figura no Exercício 9.6 calculado com o algoritmo mostrado na Seção 9.5.4. Suponha que $L = 3$ pixels.

- 9.22** ***(a)** Discuta o efeito do uso do elemento estruturante da Figura 9.15(c) para a extração de fronteiras, em vez daquele mostrado na Figura 9.13(b).

- Qual seria o efeito de usar um elemento estruturante 3×3 composto por todos os 1s no algoritmo de preenchimento de buracos da Equação 9.5-2, em vez do elemento estruturante da Figura 9.15(c)?

- 9.23** ***(a)** Proponha um método (usando qualquer uma das técnicas mostradas nas seções 9.1 até 9.5) para automatizar o exemplo da Figura 9.16. Você pode considerar que as esferas não se tocam e que ninguém tocou na borda da imagem.

- Repita (a), mas desta vez permitindo que as esferas se toquem de forma arbitrária, inclusive tocando a borda da imagem.

- *9.24** O algoritmo dado na Seção 9.5.3 para extração dos componentes conexos requer que um ponto seja conhecido em cada componente conexo, a fim de extrair todos eles. Suponha que você receba uma imagem binária contendo um número arbitrário (desconhecido) de componentes conexos. Proponha um processo totalmente automatizado para extrair todos os componentes conexos. Suponha que os pontos pertencentes aos componentes conexos são rotulados com 1, e os pontos de fundo são rotulados com 0.

- 9.25** Proponha uma expressão com base na reconstrução por dilatação capaz de extrair todos os buracos em uma imagem binária.

- 9.26** Em relação ao algoritmo de preenchimento de buracos da Seção 9.5.9:

- Explique o que aconteceria se todos os pontos da borda de f fossem 1.
- Se o resultado em (a) é o que você esperava, explique o porquê. Se o resultado não for o esperado, explique como você poderia modificar o algoritmo para que ele funcione como desejado.

- *9.27** Explique o que aconteceria na erosão e dilatação binárias se o elemento estruturante fosse um ponto único, com valor 1. Dê o(s) motivo(s) para sua resposta.

- 9.28** Conforme explicado na Equação 9.5-27 e na Seção 9.6.4, a abertura por reconstrução preserva a forma dos componentes da imagem que permanecem após a erosão. O que faz o fechamento por reconstrução?

- *9.29** Mostre que a erosão e a dilatação geodésica (Seção 9.5.9) são duais em relação à complementação de conjuntos. Isto é, mostre que $E_G^{(n)}(F) = [D_{G^c}^{(1)}[D_{G^c}^{(n-1)}(F^c)]]^c$ e, inversamente, que $D_G^{(n)}(F) = [E_{G^c}^{(1)}[E_{G^c}^{(n-1)}(F^c)]]^c$. Suponha que o elemento estruturante é simétrico em torno de sua origem.

- 9.30** Mostre que a reconstrução por dilatação e a reconstrução por erosão (Seção 9.5.9) são duais em relação à complementação de conjuntos. Isto é, mostre que $R_G^D(F) = [R_{G^c}^E(F^c)]^c$, e vice-versa, que $R_G^E(F) = [R_{G^c}^D(F^c)]^c$. Suponha que o elemento estruturante é simétrico em torno de sua origem.

- *9.31** Crie um argumento mostrando que:

- $[(F \ominus nB)]^c = (F^c \oplus n\hat{B})$, onde $(F \ominus nB)$ indica n erosões de F por B .
- $[(F \oplus nB)]^c = (F^c \ominus n\hat{B})$.

- 9.32** Mostre que o fechamento binário por reconstrução é o dual da abertura por reconstrução no que diz respeito à complementação de conjuntos: $O_R^{(n)}(F) = [C_R^{(n)}(F^c)]^c$, e, da mesma forma

$C_R^{(n)}(F) = [O_R^{(n)}(F^c)]^c$. Suponha que o elemento estruturante é simétrico em torno de sua origem.

- 9.33** Prove a validade das expressões a seguir de morfologia em níveis de cinza. Você pode assumir que b é um elemento estruturante plano. Lembre-se que $f^c(x, y) = -f(x, y)$, e que $\hat{b}(x, y) = b(-x, -y)$.

***(a)** Dualidade da erosão e da dilatação: $(f \ominus b)^c = f^c \oplus \hat{b}$ e $(f \oplus b)^c = f^c \ominus \hat{b}$.

(b) $(f \bullet b)^c = f^c \circ \hat{b}$ e $(f \circ b)^c = f^c \bullet \hat{b}$.

***(c)** $D_g^{(n)}(f) = [E_{g^c}^{(1)}[E_{g^c}^{(n-1)}(f^c)]]^c$ e $E_g^{(n)}(f) = [D_{g^c}^{(1)}[D_{g^c}^{(n-1)}(f^c)]]^c$. Considere um elemento estruturante simétrico.


(d) $R_g^D(f) = [R_{g^c}^E(f^c)]^c$ e $R_g^E(f) = [R_{g^c}^D(f^c)]^c$.

(e) $[(f \ominus nb)^c] = (f^c \oplus n\hat{b})$, onde $(f \ominus nb)$ indica n erosões de f por b . Também que $[(f \oplus nb)^c] = (f^c \ominus n\hat{b})$.

(f) $O_R^{(n)}(f) = [C_R^{(n)}(f^c)]^c$ e $C_R^{(n)}(f) = [O_R^{(n)}(f^c)]^c$. Suponha que o elemento estruturante seja simétrico em torno de sua origem.

- 9.34** Na Figura 9.43, uma fronteira entre as diferentes regiões de textura foi criada sem dificuldades. Considere a imagem a seguir, que mostra uma região de pequenos círculos englobados por uma região de círculos maiores.

- (a)** Será que o método usado para gerar a Figura 9.43(d) funcionaria com esta imagem também? Explique seu raciocínio, incluindo as suposições que você precisa fazer para que o método funcione.
- (b)** Se a sua resposta for sim, esboce a forma que ficaria a fronteira.



- 9.35** Uma imagem em níveis de cinza, $f(x, y)$, é corrompida por picos de ruído que não se sobrepõem e que podem ser modelados como pequenos artefatos cilíndricos de raios $R_{\min} \leq r \leq R_{\max}$ e amplitude $A_{\min} \leq a \leq A_{\max}$.

- *(a)** Desenvolva uma metodologia de filtragem morfológica para limpar a imagem.


- (b)** Repita (a), mas desta vez imagine que há sobreposição de, no máximo, quatro picos de ruído.

- 9.36** Uma etapa de pré-processamento para um aplicativo de microscopia aborda o problema de isolar partículas redondas individuais de partículas semelhantes que se sobrepõem em grupos de duas ou mais partículas (ver imagem a seguir). Partindo do princípio de que todas as partículas são do mesmo tamanho, proponha um algoritmo morfológico que produza três imagens que possuam, respectivamente:


- *(a)** Apenas partículas que se fundiram com a borda da imagem.

- (b)** Apenas partículas sobrepostas.

- (c)** Apenas partículas que não se sobrepõem.



- 9.37** Uma fábrica de produção de alta tecnologia ganha um contrato com o governo para fabricar máquinas de lavar de alta precisão, com a forma mostrada na figura a seguir. O contrato exige que a forma de todas as máquinas seja inspecionada por um sistema de imagem. Nesse contexto, a inspeção da forma refere-se a irregularidades no formato arredondado nas bordas internas e externas das máquinas. Você pode assumir o seguinte: (1) uma imagem “de ouro” (perfeita no que diz respeito ao problema) de uma máquina de lavar aceitável está disponível; e (2) a imagem e os sistemas de posicionamento utilizados atualmente possuem precisão alta o suficiente para permitir que você ignore os erros devidos à digitalização e ao posicionamento. Você foi contratado como consultor para ajudar a especificar a parte de inspeção visual do sistema. Proponha uma solução baseada nas operações morfológicas/lógicas. Sua resposta deve estar na forma de um diagrama de blocos.



Capítulo 10

Segmentação de imagens

O todo é igual à soma das suas partes.

Euclides

O todo é maior que a soma de suas partes.

Max Wertheimer

Apresentação

O material do capítulo anterior começou uma transição dos métodos de processamento de imagem cujas entradas e saídas são imagens para métodos em que as entradas são imagens, mas as saídas são atributos extraídos dessas imagens (no sentido definido na Seção 1.1). A segmentação é um passo importante nessa direção.

A segmentação subdivide uma imagem em regiões ou objetos que a compõem. O nível de detalhe em que a subdivisão é realizada depende do problema a ser resolvido. Ou seja, a segmentação deve parar quando os objetos ou as regiões de interesse de uma aplicação forem detectados. Por exemplo, na inspeção automatizada de componentes eletrônicos, o interesse está em analisar as imagens dos produtos com o intuito de determinar a presença ou ausência de anomalias específicas, como a falta de componentes ou circuitos de conexão interrompidos. Não há sentido nenhum na execução da segmentação além do nível de detalhamento necessário para identificar esses elementos.

A segmentação de imagens não triviais é uma das tarefas mais difíceis no processamento de imagens. A precisão da segmentação determina o sucesso ou o fracasso final dos procedimentos de análise computadorizada. Por essa razão, deve-se tomar muito cuidado para aumentar a probabilidade de se obter uma segmentação precisa. Em algumas situações, como nas aplicações de controle industrial, é possível pelo menos alguma medida de controle sobre o ambiente. Um experiente desenvolvedor de sistemas de processamento de imagens deve prestar muita atenção nessas oportunidades. Em outras aplicações, como a busca autônoma de alvos, o desenvolvedor do sistema não tem controle sobre o ambiente no qual o sistema opera, e a abordagem usual consiste em centrar-se na seleção dos tipos de sensores que provavelmente vão realçar os objetos de interesse, diminuindo a contribuição dos detalhes irrelevantes da imagem. Um bom exemplo é o uso da imagem infravermelha pelos militares para detectar objetos com forte emissão de calor, como equipamentos e tropas em movimento.

A maioria dos algoritmos de segmentação neste capítulo baseia-se em uma das seguintes propriedades básicas de valores de intensidade: descontinuidade e similaridade.* Na primeira categoria, a abordagem é dividir uma imagem com base nas mudanças bruscas de intensidade, como as bordas. As abordagens principais na segunda categoria estão baseadas na divisão de uma imagem em regiões que sejam semelhantes de acordo com um conjunto de critérios predefinidos. A limiarização, o crescimento de região e a divisão e fusão de regiões são exemplos dos métodos desta categoria. Neste capítulo, discutiremos e ilustraremos uma série de abordagens e mostraremos que as melhorias no desempenho da segmentação podem ser alcançadas com a combinação de métodos de categorias diferentes, como as técnicas cuja a detecção de bordas é combinada com a limiarização. Discutiremos também a segmentação de imagens baseada em morfologia. Essa abordagem é particularmente interessante porque combina vários dos atributos positivos da segmentação com base nas técnicas apresentadas na primeira parte do capítulo. Concluiremos o capítulo com uma breve discussão sobre a segmentação utilizando dicas de movimento.

* Veja as seções 6.7 e 10.3.8 para uma discussão quanto às técnicas de segmentação baseadas em mais elementos além dos valores de cinza (intensidade).

10.1 Fundamentos

Digamos que R represente toda a região espacial ocupada por uma imagem. Podemos ver a segmentação da imagem como um processo que particiona R em n sub-regiões, $R_1, R_2, \dots, R_n$, de tal forma que

- (a) $\bigcup_{i=1}^n R_i = R$
- (b) R_i é um conjunto conectado, $i = 1, 2, \dots, n$.
- (c) $R_i \cap R_j = \emptyset$ para todo i e j , $i \neq j$
- (d) $Q(R_i) = \text{VERDADEIRA}$ para $i = 1, 2, \dots, n$.
- (e) $Q(R_i \cup R_j) = \text{FALSA}$ para quaisquer regiões adjacentes R_i e R_j .

Aqui, $Q(R_k)$ é uma propriedade lógica definida sobre os pontos no conjunto R_k , e $\emptyset$ é o conjunto nulo. Os símbolos $\cup$ e $\cap$ representam a união e a interseção do conjunto, respectivamente, conforme definido na Seção 2.6.4. Duas regiões R_i e R_j são ditas *adjacentes* se a sua união forma um conjunto conexo, como discutido na Seção 2.5.2.

A condição (a) indica que a segmentação deve ser completa, isto é, cada pixel deve estar em uma região. A condição (b) requer que os pontos em uma região estejam conectados de alguma forma predefinida (por exemplo, os pontos devem ser 4- ou 8-conectados, conforme definido na Seção 2.5.2). A condição (c) indica que as

regiões devem estar separadas. A condição (d) tem a ver com as propriedades que devem ser cumpridas pelos pixels em uma região segmentada — por exemplo, $Q(R_i) = \text{VERDADEIRA}$ se todos os pixels em R_i possuírem o mesmo nível de intensidade. Finalmente, a condição (e) indica que duas regiões adjacentes, R_i e R_j , devem ser diferentes no sentido da propriedade Q .*

Assim, vemos que o problema fundamental da segmentação é a divisão de uma imagem em regiões que satisfaçam as condições anteriores. Os algoritmos de segmentação para imagens monocromáticas geralmente estão baseados em uma de duas categorias básicas relacionadas às propriedades dos valores de intensidade: descontinuidade e similaridade. Na primeira categoria, o pressuposto é que as fronteiras das regiões são suficientemente diferentes entre si e em relação ao fundo da imagem para permitir a detecção de limite com base nas descontinuidades locais em intensidade. A segmentação baseada nas bordas é a principal abordagem usada nesta categoria. As abordagens da segmentação baseada na região na segunda categoria estão baseadas na divisão de uma imagem em regiões que sejam semelhantes de acordo com um conjunto de critérios predefinidos.

A Figura 10.1 ilustra os conceitos anteriores. A Figura 10.1(a) mostra uma imagem de uma região de intensidade




Figura 10.1 (a) Imagem que contém uma região de intensidade constante. (b) Imagem mostrando a fronteira da região interior, obtida a partir das descontinuidades de intensidade. (c) Resultado da segmentação da imagem em duas regiões. (d) Imagem que contém uma região com textura. (e) Resultado do cálculo da borda. Repare no grande número de pequenas bordas que estão conectadas com a fronteira original, o que torna difícil encontrar um limite único utilizando apenas a informação das bordas. (f) Resultado da segmentação baseada nas propriedades da região.

* Em geral, Q pode ser uma expressão composta, como, por exemplo, $Q(R_i) = \text{VERDADEIRA}$ se a intensidade média dos pixels em R_i for menor a m_i , E (AND) se o desvio padrão de sua intensidade for maior do que σ_i , em que m_i e σ_i são constantes especificadas.

constante sobreposta em um fundo mais escuro, também de intensidade constante. Essas duas regiões compreendem a região global da imagem. A Figura 10.1(b) mostra o resultado do cálculo da fronteira da região interna baseado nas discontinuidades de intensidade. Os pontos no interior e no exterior da fronteira são pretos (zero) porque não há nenhuma discontinuidade na intensidade nessas regiões. Para segmentar a imagem, podemos atribuir um nível (digamos, branco) para os pixels sobre ou no interior da fronteira e outro nível (digamos, preto) para todos os pontos do lado de fora da fronteira. A Figura 10.1(c) mostra o resultado desse procedimento. Vemos que as condições (a) até (c) estabelecidas no início desta seção são cumpridas com este resultado. A propriedade da condição (d) é: se um pixel está sobre ou dentro da fronteira, a etiqueta é branca; caso contrário, a etiqueta é preta. Vemos que essa propriedade é VERDADEIRA para os pontos rotulados em preto e branco na Figura 10.1(c). Da mesma forma, as duas regiões segmentadas (objeto e fundo) satisfazem a condição (e).

As três imagens a seguir ilustram a segmentação baseada na região. A Figura 10.1(d) é semelhante à Figura 10.1(a), mas as intensidades da região interna formam um padrão texturizado. A Figura 10.1(e) mostra o resultado do cálculo das bordas desta imagem. É evidente que as numerosas mudanças artificiais na intensidade fazem com que seja difícil identificar uma fronteira única na imagem original, porque muitas das mudanças de intensidade diferentes de zero estão conectadas à fronteira, de modo que a segmentação baseada na borda não é um método adequado. Observamos, no entanto, que a região externa é constante, então tudo o que precisamos para resolver esse problema de segmentação simples é uma propriedade que faça a diferença entre as regiões constantes e as texturizadas. O desvio padrão dos valores dos pixels é uma medida que faz isso porque é diferente de zero nas áreas da região de textura e é zero no caso contrário. A Figura 10.1(f) mostra o resultado de dividir a imagem original em sub-regiões de tamanho 4×4 . Cada sub-região foi, então, rotulada como branca se o desvio padrão de seus pixels era positivo (ou seja, se a propriedade era VERDADEIRA) e zero caso contrário. O resultado foi uma aparência de “blocos” ao redor da borda da região em decorrência de os grupos de 4×4 terem sido rotulados com a mesma intensidade. Finalmente, repare que esses resultados também cumprem com as cinco condições estabelecidas no início desta seção.

10.2 Detecção de ponto, linha e borda

O tema principal desta seção são os métodos de segmentação baseados na detecção de mudanças *locais* abruptas

de intensidade. Os três tipos de características da imagem em que estamos interessados são os pontos isolados, as linhas e as bordas. **Os pixels de borda são pixels em que a intensidade de uma função imagem muda abruptamente, e as bordas (ou segmentos de borda) são conjuntos de pixels de borda conexos** (ver Seção 2.5.2 em relação à conectividade). **Os detectores de borda são métodos de processamento de imagem local desenvolvidos para detectar os pixels da borda.** Uma linha pode ser vista como um segmento de borda em que a intensidade do fundo de cada lado da linha ou é muito superior ou muito inferior à intensidade dos pixels da linha. De fato, como discutiremos na seção a seguir e na Seção 10.2.4, as linhas dão origem às chamadas “bordas em forma de telhado” ou *roof edges*. Da mesma forma, um ponto isolado pode ser visto como uma linha cujo comprimento e largura são iguais a um pixel.*

10.2.1 Fundamentos

Como vimos nas seções 2.6.3 e 3.5, o filtro de média local suaviza a imagem. Dado que a suavização pela média se assemelha à integração, **não surpreende que as mudanças locais abruptas na intensidade possam ser detectadas usando derivadas. Por razões que se tornarão evidentes em breve, as derivadas de primeira e segunda ordem são particularmente adequadas para essa finalidade.**

As derivadas de uma função digital são definidas em termos de diferenças. Existem várias maneiras de abordar essas diferenças, mas, como explicado na Seção 3.6.1, é preciso que qualquer aproximação utilizada para uma primeira derivada (1) seja zero nas áreas de intensidade constante; (2) seja diferente de zero no início de um degrau ou rampa de intensidade; e (3) que seja diferente de zero em pontos ao longo de uma rampa de intensidade. Da mesma forma, é preciso que qualquer aproximação utilizada para uma derivada de segunda ordem (1) seja zero nas áreas de intensidade constante; (2) seja diferente de zero no início e no final de uma rampa ou degrau de intensidade; e (3) seja diferente de zero ao longo das rampas de intensidade. Já que estamos lidando com quantidades digitais cujos valores são finitos, **a variação máxima possível de intensidade também é finita, e a menor distância na qual uma mudança pode ocorrer é entre pixels adjacentes.**

Obtemos uma aproximação para a derivada de primeira ordem no ponto x de uma função bidimensional $f(x)$,

* Quando falamos em linhas, estamos nos referindo a estruturas finas que geralmente têm apenas alguns pixels de espessura. Essas linhas podem corresponder, por exemplo, aos elementos de um desenho arquitetônico digitalizado ou estradas em uma imagem de satélite.

expandindo a função $f(x + \Delta x)$ em uma série de Taylor sobre x , assumindo que $\Delta x = 1$ e mantendo apenas os termos lineares (Exercício 10.1). O resultado é a diferença digital*

$$\frac{\delta f}{\delta x} = f'(x) = f(x+1) - f(x) \quad (10.2-1)$$

Utilizaremos aqui uma derivada parcial para ter mais consistência na notação quando consideramos uma imagem como uma função de duas variáveis, $f(x, y)$, quando trabalharmos com derivadas parciais ao longo dos dois eixos. Claramente, $\partial f / \partial x = df/dx$, quando f é uma função de uma única variável.

Obtemos uma expressão para a segunda derivada diferenciando a Equação 10.2-1 com relação a x :

$$\begin{aligned} \frac{\partial^2 f}{\partial x^2} &= \frac{\partial f'(x)}{\partial x} = f'(x+1) - f'(x) \\ &= f(x+2) - f(x+1) - f(x+1) + f(x) \\ &= f(x+2) - 2f(x+1) + f(x) \end{aligned}$$

na qual a segunda linha resulta da Equação 10.2-1. Essa expansão é sobre o ponto $x+1$. Nosso interesse está na segunda derivada sobre o ponto x , de modo que subtraímos 1 dos argumentos na expressão anterior e obtemos o resultado

$$\frac{\partial^2 f}{\partial x^2} = f''(x) = f(x+1) + f(x-1) - 2f(x) \quad (10.2-2)$$

É fácil verificar que as equações 10.2-1 e 10.2-2 satisfazem as condições definidas no início desta seção sobre as derivadas de primeira e segunda ordem. Para ilustrar este ponto e destacar as semelhanças e diferenças fundamentais entre as derivadas de primeira e segunda ordem no contexto do processamento de imagem, considere a Figura 10.2.

A Figura 10.2(a) mostra uma imagem que contém vários objetos sólidos, uma linha e um ponto interno de ruído. A Figura 10.2(b) mostra um perfil de intensidade horizontal (linha de digitalização) da imagem, próximo




Figura 10.2 (a) Imagem (b) Perfil de intensidade horizontal no centro da imagem, incluindo o ponto de ruído isolado, (c) Perfil simplificado (os pontos estão unidos com traços para facilitar o entendimento). A faixa da imagem corresponde ao perfil de intensidade, e os números nas caixas são os valores de intensidade dos pontos mostrados no perfil. As derivadas foram obtidas utilizando as equações 10.2-1 e 10.2-2.

* Lembre-se, da Seção 2.4.2, que os incrementos entre as amostras de imagens são definidos como uma unidade para maior clareza na notação, daí o uso de $\Delta x = 1$ na derivação da Equação 10.2-1.

ao centro, incluindo o ponto isolado. As transições de intensidade entre os objetos sólidos e o fundo ao longo da linha de digitalização mostram dois tipos de bordas: *bordas em rampa* (à esquerda) e *bordas em degrau* (à direita). Como discutiremos mais tarde, as transições de intensidade envolvendo objetos finos como linhas muitas vezes são chamados de *bordas em forma de telhado*. A Figura 10.2(c) mostra uma simplificação do perfil, com pontos suficientes para que possamos analisar numericamente a forma em que as derivadas de primeira e segunda ordem se comportam quando encontram um ponto de ruído, uma linha e as bordas dos objetos. Nesse diagrama simplificado, a transição na rampa abrange quatro pixels, o ponto de ruído é um pixel único, a linha é de três pixels de espessura e a transição em degrau de intensidade ocorre entre pixels adjacentes. O número de níveis de intensidade limita-se a oito, por motivos de simplicidade.

Considere as propriedades das derivadas de primeira e segunda ordem conforme percorremos o perfil da esquerda para a direita. Inicialmente, observamos que a derivada de primeira ordem é diferente de zero no início e ao longo de toda a rampa de intensidade, enquanto a derivada de segunda ordem é diferente de zero apenas no início e no final da rampa. Já que as bordas das imagens digitais se parecem com este tipo de transição, podemos concluir que as derivadas de primeira ordem produzem bordas “grossas”, e as de segunda ordem produzem bordas muito mais finas. Em seguida, encontramos o ponto de ruído isolado. Aqui, a magnitude da resposta no ponto é muito mais forte para a derivada de segunda ordem do que para a de primeira ordem. Isso não é uma surpresa, porque uma derivada de segunda ordem é muito mais agressiva do que uma derivada de segunda ordem na hora de facilitar as mudanças bruscas.

Assim, podemos esperar que as derivadas de segunda ordem melhorem os pequenos detalhes (incluindo o ruído) com mais eficiência do que as derivadas de primeira ordem. A linha neste exemplo é bastante fina; por isso, seus detalhes também são finos e vemos mais uma vez que a derivada de segunda ordem tem uma magnitude maior. Finalmente, observe, tanto nas bordas em rampa quanto nas bordas em degrau, que a segunda derivada tem sinais opostos (negativo para positivo ou positivo para negativo) conforme entra e sai da borda. Esse efeito de “borda dupla” é uma característica importante que, como mostramos na Seção 10.2.6, pode ser usado para localizar as bordas. O sinal da segunda derivada também é utilizado para determinar se uma borda é uma transição de claro a escuro (segunda derivada negativa) ou de

escuro para claro (segunda derivada positiva), em que o sinal é observado conforme nos aproximamos da borda.

Em resumo, chegamos às seguintes conclusões: (1) as derivadas de primeira ordem geralmente produzem bordas mais grossas em uma imagem. (2) As derivadas de segunda ordem têm uma resposta mais forte aos detalhes finos, como linhas finas, pontos isolados e ruído. (3) As derivadas de segunda ordem produzem uma resposta de borda dupla nas transições de rampa e de degrau de intensidade. (4) O sinal da segunda derivada pode ser usado para determinar se uma transição em uma borda é de claro para escuro ou vice-versa.

A melhor estratégia para o cálculo das derivadas de primeira e segunda ordem em cada posição de pixel em uma imagem é a utilização de filtros espaciais. Para o filtro com máscara 3×3 da Figura 10.3, o procedimento consiste em calcular a soma dos produtos dos coeficientes da máscara com os valores de intensidade na região compreendida pela máscara. Isto é, com referência à Equação 3.4.3, a resposta da máscara no ponto central da região é

$$R = \omega_1 z_1 + \omega_2 z_2 + \dots + \omega_9 z_9 \\ = \sum_{k=1}^9 \omega_k z_k \quad (10.2-3)$$

na qual z_k é a intensidade do pixel cuja localização espacial corresponde à posição do k -ésimo coeficiente da máscara. Os detalhes da execução desta operação em todos os pixels de uma imagem são discutidos em detalhe nas seções 3.4 e 3.6. Em outras palavras, o cálculo das derivadas baseado nas máscaras espaciais é a filtragem espacial de uma imagem com essas máscaras, como explicado nessas seções.*

w_1	w_2	w_3
w_4	w_5	w_6
w_7	w_8	w_9

Figura 10.3 Uma máscara geral de filtro espacial 3×3 .

* Conforme explicado na Seção 3.4.3, a Equação 10.2-3 é uma notação simplificada, seja para a correlação espacial, dada pela Equação 3.4-1, seja pela convolução espacial, dada pela Equação 3.4-2. Portanto, quando R é avaliado em todos os locais de uma imagem, o resultado é um arranjo. Toda a filtragem espacial neste capítulo é feita usando correlação. Em alguns casos, usamos o termo convolução de uma máscara com uma imagem para fins de manter a convenção. No entanto, só usamos essa terminologia quando as máscaras de filtro são simétricas, caso em que a correlação e a convolução produzem o mesmo resultado.

10.2.2 Detecção de pontos isolados

Com base nas conclusões da seção anterior, sabemos que a detecção de pontos deve-se basear nas técnicas que utilizam as derivadas de segunda ordem. A partir da discussão na Seção 3.6.2, isso implica utilizar o laplaciano:

$$\nabla^2 f(x, y) = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2} \quad (10.2-4)$$

sendo que as derivadas parciais são obtidas usando a Equação 10.2-2:

$$\frac{\partial^2 f(x, y)}{\partial x^2} = f(x+1, y) + f(x-1, y) - 2f(x, y) \quad (10.2-5)$$

e

$$\frac{\partial^2 f(x, y)}{\partial y^2} = f(x, y+1) + f(x, y-1) - 2f(x, y) \quad (10.2-6)$$

O laplaciano é, então,

$$\nabla^2 f(x, y) = f(x+1, y) + f(x-1, y) + f(x, y+1) + f(x, y-1) - 4f(x, y) \quad (10.2-7)$$

Conforme explicado na Seção 3.6.2, essa expressão pode ser implementada usando a máscara da Figura 3.379(a). Além disso, como explicado nessa seção, podemos estender a Equação 10.2-7 para incluir os termos diagonais e usar a máscara da Figura 3.37(b). Usando a máscara laplaciana na Figura 10.4(a), que é idêntica à máscara da Figura 3.37(b), dizemos que um ponto foi detectado no local (x, y) em que a máscara está centrada se o módulo do valor de resposta da máscara nesse ponto exceder um limiar estabelecido. Esses pontos são rotulados como 1 na imagem de saída, e todos os outros são rotulados 0, produzindo, assim, uma imagem binária. Em outras palavras, a saída é obtida utilizando a seguinte expressão:

$$g(x, y) = \begin{cases} 1 & \text{se } |R(x, y)| \geq T \\ 0 & \text{caso contrário} \end{cases} \quad (10.2-8)$$

na qual g é a imagem de saída, T é um limiar não negativo, e R é dado pela Equação 10.2-3. Essa formulação simplesmente mede as diferenças ponderadas entre um pixel e seus vizinhos-8. Intuitivamente, a ideia é que a intensidade de um ponto isolado será muito diferente do seu entorno e, portanto, será facilmente detectável por esse tipo de máscara. As únicas diferenças de intensidade que são de interesse são aquelas suficientemente grandes (como determinado por T) para serem consideradas pontos isolados. Repare que, como é usual para uma máscara derivada, a soma de coeficientes é zero, indicando que a resposta da máscara será zero nas áreas de intensidade constante.

Exemplo 10.1 Detecção de pontos isolados em uma imagem.

Ilustramos a segmentação de pontos isolados em uma imagem com o auxílio da Figura 10.4(b), que é uma radiografia de uma lâmina de turbina de um motor de um jato. A lâmina tem uma porosidade no quadrante superior direito da imagem e não há um único pixel preto embutido dentro da porosidade. A Figura 10.4(c) é o resultado da aplicação da máscara detectora de pontos para a radiografia e a Figura 10.4(d) mostra o resultado do uso da Equação 10.2-8 com T igual a 90% do maior valor absoluto dos pixels existentes na Figura 10.4(c). O pixel é claramente visível nesta imagem (o pixel foi ampliado manualmente para melhorar sua visibilidade). Esse tipo de processo de detecção é bastante especializado porque é baseado nas mudanças abruptas da intensidade em locais de um único pixel que estão cercadas por um fundo homogêneo na área da máscara detectora. Quando essa condição não é satisfeita, outros métodos discutidos neste capítulo são mais adequados para detectar mudanças de intensidade.

10.2.3 Detecção de linhas

O próximo nível de complexidade é a detecção de linha. Com base na discussão da Seção 10.2.1, sabemos que, para a detecção de linha, podemos esperar que as derivadas de segunda ordem resultem em uma resposta mais forte e produzam linhas mais finas do que as derivadas de




Figura 10.4 (a) Máscara de detecção de pontos (laplaciana). (b) Radiografia da uma lâmina de turbina com porosidade. A porosidade contém um único pixel preto. (c) Resultado da convolução da máscara com a imagem. (d) Resultado da utilização da Equação 10.2-8 mostrando um único ponto (o ponto foi ampliado para tornar mais fácil sua visualização). (Imagem original: cortesia da X-TEK Systems, Ltd.)

primeira ordem. Assim, podemos usar a máscara laplaciana na Figura 10.4(a) para a detecção de linhas também, levando em consideração que o efeito de linha dupla da segunda derivada deve ser tratado adequadamente. O exemplo a seguir ilustra o procedimento.

Exemplo 10.2 Utilizando o filtro laplaciano para a detecção de linhas.

A Figura 10.5(a) mostra uma porção 486×486 (binária) de uma conexão *wire-bond* de um circuito eletrônico, e a Figura 10.5(b) mostra a mesma imagem após ter sido submetida ao filtro laplaciano. Já que a imagem laplaciana contém valores negativos,* o ajuste é necessário para poder mostrar o processo. Como mostra a seção ampliada, o cinza médio representa zero, os tons mais escuros de cinza representam valores negativos e tons mais claros são positivos. O efeito de linha dupla é claramente visível na região ampliada.

À primeira vista, pode parecer que os valores negativos podem ser tratados simplesmente tomando como resposta o módulo dos valores calculados pelo filtro laplaciano.




Figura 10.5 (a) Imagem original. (b) Imagem resultante do filtro laplaciano; a seção ampliada mostra o efeito de linha dupla positivo/negativo característico do filtro laplaciano. (c) Valor absoluto do filtro laplaciano. (d) Valores positivos do filtro laplaciano.

* Quando uma máscara cuja soma dos coeficientes é zero faz convolução com uma imagem, os pixels da imagem resultante também somarão zero (Exercício 3.16), sugerindo a existência de pixels tanto positivos quanto negativos no resultado. Um ajuste de intensidades de modo que todos os valores sejam não negativos é necessário para fins de exibição.

No entanto, como apresentado na Figura 10.5(c), essa abordagem dobra a espessura das linhas. Uma metodologia mais adequada consiste em utilizar apenas os valores positivos do filtro laplaciano (em situações ruidosas utilizamos os valores que excedem o limiar positivo para eliminar as variações aleatórias ao redor de zero causadas pelo ruído). Como a imagem na Figura 10.5(d) mostra, essa abordagem resulta em linhas mais finas, que são consideravelmente mais úteis. Note nas figuras 10.5(b) a (d), que, quando as linhas são largas comparadas com o tamanho da máscara laplaciana, as linhas são separadas por um “vale” de zeros.

Isto não é uma surpresa. Por exemplo, quando o filtro 3×3 é centrado em uma linha de intensidade constante de 5 pixels de largura, a resposta será zero, produzindo o efeito de “vale” mencionado acima. Quando falamos sobre detecção de linhas, o pressuposto é que as linhas são finas se comparadas com o tamanho do detector. É melhor tratar as linhas que não cumprem essa hipótese como regiões e manipulá-las usando os métodos de detecção de bordas que discutiremos ainda nesta seção.

O detector laplaciano apresentado na Figura 10.4(a) é isotrópico e, por isso, sua resposta independe da direção (em relação às quatro direções da máscara laplaciana 3×3 : verticais, horizontais e duas diagonais). Muitas vezes, o interesse reside na detecção de linhas em direções específicas. Considere as máscaras na Figura 10.6. Suponha que uma imagem com um fundo constante e que contém várias linhas (orientadas a 0° , $\pm 45^\circ$ e 90°) é filtrada com a primeira máscara.** As respostas máximas ocorrerão em locais da imagem em que uma linha horizontal atravessou a linha do meio da máscara. Isso é facilmente comprovado esboçando um arranjo simples de 1s com uma linha de diferentes intensidades (digamos, 5s) na direção horizontal do arranjo. Uma experiência semelhante revelaria que a segunda máscara na Figura 10.6 responde melhor às linhas com 45° de inclinação; a terceira máscara para linhas verticais e a quarta máscara, para linhas com -45° de inclinação. A direção preferencial de cada máscara é ponderada com um coeficiente maior (ou seja, 2) do que os outros sentidos possíveis. Os coeficientes de cada máscara somam zero, indicando uma resposta nula em áreas de intensidade constante.

Digamos que R_1 , R_2 , R_3 e R_4 denotam as respostas das máscaras apresentadas na Figura 10.6, da esquerda

** Lembre-se que, na Seção 2.4.2, dizíamos que convencionalmente os eixos da imagem têm sua origem no canto superior esquerdo, e o eixo x positivo aponta para baixo, enquanto o eixo y positivo se estende à direita. Os ângulos das linhas discutidas nesta seção são medidos em relação ao eixo x positivo. Por exemplo, uma linha vertical tem um ângulo de 0° e uma linha de $+45^\circ$ se estende para baixo e para a direita.

-1	-1	-1	2	-1	-1	-1	2	-1	-1	-1	-1	2
2	2	2	-1	2	-1	-1	2	-1	-1	2	2	-1
-1	-1	-1	-1	-1	2	-1	2	-1	2	-1	-1	-1
Horizontal			+45°			Vertical			-45°			

Figura 10.6 Máscaras de detecção de linhas. Os ângulos são em relação ao sistema de eixos da Figura 2.18(b).

para a direita, em que os R_s são dados pela Equação 10.2-3*. Suponha que uma imagem seja filtrada (individualmente) com as quatro máscaras. Se, em um certo, $|R_k| > |R_j|$, para todos $j \neq k$, esse ponto tem maior probabilidade de ser associado a uma linha na direção da máscara k . Por exemplo, se em um ponto na imagem, $|R_1| > |R_j|$, para $j = 2, 3, 4$, esse ponto em particular tem mais probabilidades de ser associado a uma linha horizontal. Alternativamente, podemos estar interessados na detecção de linhas em uma direção especificada. Nesse caso, poderíamos usar a máscara associada a essa direção e estabelecer um limiar na sua saída, como na Equação 10.2-8. Em outras palavras, se estamos interessados em detectar todas as linhas em uma imagem no sentido definido por uma máscara específica, simplesmente executamos a máscara por meio da imagem e estabelecemos um limiar comparando-o ao módulo do valor do resultado. Os pontos que sobra-rem serão as respostas mais fortes que, para as linhas de 1 pixel de espessura, têm maior probabilidade de corresponder à direção definida pela máscara. O exemplo a seguir ilustra o procedimento.

Exemplo 10.3 Detecção de linhas em direções específicas.

A Figura 10.7(a) mostra a imagem usada no exemplo anterior. Suponha que estamos interessados em encontrar todas as linhas que são de 1 pixel de espessura e com inclinação de 45°. Para esse fim, usamos a segunda máscara apresentada na Figura 10.6. A Figura 10.7(b) é o resultado da filtragem da imagem com aquela máscara. Como antes, os tons mais escuros do que o fundo cinza na Figura 10.7(b) correspondem aos valores negativos. Existem dois segmentos principais na imagem com inclinação de +45°, uma na parte superior esquerda e a outra na parte inferior




Figura 10.7 (a) Imagem de uma conexão *wire-bond*. (b) Resultado do processamento utilizando a máscara detectora de linha de +45° na Figura 10.6. (c) Vista ampliada da região posicionada no canto superior esquerdo de (b). (d) Vista ampliada da região posicionada no canto inferior direito de (b). (e) A imagem em (b) com todos os valores negativos zerados. (f) Todos os pontos (em branco), cujos valores cumpriram a condição $g \geq T$, na qual g é a imagem em (e). (Os pontos em (f) foram ampliados para que fosse mais fácil de ver.)

* Não confunda o uso de R para designar a resposta da máscara com o R utilizado para para designar regiões na Seção 10.1.

direita. As figuras 10.7(c) e (d) mostram seções ampliadas da Figura 10.7(b) correspondentes a essas duas áreas. Repare quão mais claro é o segmento de reta apresentado na Figura 10.7(d), comparado com o segmento apresentado na Figura 10.7(c). A razão é que o segmento de linha no canto inferior direito da Figura 10.7(a) é de 1 pixel de espessura, diferentemente daquele na parte superior esquerda. A máscara está “sintonizada” para detectar linhas de 1 pixel de espessura com inclinação de $+45^\circ$, por isso esperamos que sua resposta seja mais forte quando essas linhas são detectadas. A Figura 10.7(e) mostra os valores positivos da Figura 10.7(b). Já que estamos interessados na resposta mais forte, vamos deixar T igual ao maior valor de pixel encontrado na imagem representada na Figura 10.7(e). A Figura 10.7(f) mostra em branco os pontos cujos valores satisfizeram a condição $g \geq T$, em que g é a imagem da Figura 10.7(e). Os pontos isolados na figura são pontos que também tiveram respostas igualmente fortes para a máscara. Na imagem original, esses pontos e seus vizinhos imediatos estão orientados de tal maneira que a máscara produziu uma resposta máxima nesses locais. Esses pontos isolados podem ser detectados usando a máscara da Figura 10.4(a) e, em seguida, eliminados, ou podem ser excluídos usando operadores morfológicos, como discutido no Capítulo 9.

10.2.4 Modelos de borda

A detecção de bordas é o método usado mais frequentemente para segmentar as imagens com base nas variações abruptas (locais) de intensidade. Começamos por introduzir diversas formas para modelar as bordas e discutiremos uma série de metodologias para a detecção de bordas.

Os modelos de borda são classificados de acordo com seus perfis de intensidade. Uma *borda em degrau* envolve uma transição entre dois níveis de intensidade que ocorrem idealmente com uma distância de 1 pixel. A Figura 10.8(a) mostra a seção de uma borda vertical em degrau e o perfil de intensidade horizontal da borda. As bordas em degrau ocorrem, por exemplo, em imagens geradas por computador para uso em áreas como a modelagem de sólidos e animações. Essas bordas, limpas e ideais, podem ocorrer com uma distância de 1 pixel, desde que nenhum processamento adicional (como a suavização) seja usado

para fazê-las parecer “reais”. As bordas digitais em degrau são utilizadas com frequência como modelos de borda no desenvolvimento de algoritmos. Por exemplo, o algoritmo de detecção de bordas de Canny, discutido na Seção 10.2.6, foi calculado a partir de um modelo de borda em degrau.

Na prática, as imagens digitais têm bordas que são desfocadas e ruidosas, cujo grau de indefinição está determinado principalmente pelas limitações no mecanismo de focalização (ou seja, as lentes, no caso das imagens óticas) e o nível de ruído determinado principalmente pelos componentes eletrônicos do sistema de imagens. Em tais situações, as bordas são modeladas mais apropriadamente designando um perfil de *rampa* na intensidade, como a borda da Figura 10.8(b). A inclinação da rampa é inversamente proporcional ao grau de indefinição da borda. Nesse modelo, não temos mais uma borda fina (1 pixel de espessura). Em vez disso, um ponto de borda agora é qualquer ponto contido na rampa, e um segmento de borda seria, então, um conjunto desses pontos conectados.

Um terceiro modelo de borda é a chamada *borda em forma de telhado* ou *roof edge*, cujas características são ilustradas na Figura 10.8(c). As bordas em forma de telhado são modelos de linhas através de uma região, com a base (largura) de uma borda em forma de telhado determinada pela espessura e a nitidez da linha. No limite, quando sua base é de 1 pixel de largura, uma borda em forma de telhado realmente não é nada mais do que uma linha com 1 pixel de espessura que atravessa uma região da imagem. As bordas em forma de telhado surgem, por exemplo, nas imagens em profundidade, quando os objetos finos (como tubos) estão mais próximos do sensor do que seu fundo equidistante (como paredes). Os tubos parecem mais claros e, assim, criam uma imagem semelhante ao modelo da Figura 10.8(c). Como já mencionado, outras áreas em que as bordas em forma de telhado aparecem rotineiramente são na digitalização de desenhos e em imagens de satélite, em que características finas, como estradas, podem ser modeladas por esse tipo de borda.

Não é incomum encontrar imagens que contenham os três tipos de bordas. Embora o borramento e o ruído resultem em alterações das formas ideais, as bordas nas ima-



Figura 10.8 Da esquerda para a direita, os modelos (representações ideais) de uma borda em degrau, em rampa e em forma de telhado e seus respectivos perfis de intensidade.

gens, que são razoavelmente abruptas e apresentam uma quantidade moderada de ruído, *lembram* as características dos modelos de borda na Figura 10.8, conforme ilustrado pelos perfis apresentados na Figura 10.9.* O que os modelos da Figura 10.8 permitem-nos fazer é escrever expressões matemáticas para as bordas no desenvolvimento de algoritmos de processamento de imagens. O desempenho destes algoritmos depende das diferenças entre as bordas reais e os modelos utilizados no desenvolvimento dos algoritmos.

A Figura 10.10(a) mostra a imagem da qual foi extraído o segmento na Figura 10.8(b). A Figura 10.10(b) mostra um perfil de intensidade horizontal. Esta figura mostra também a primeira e segunda derivadas do perfil de intensidade. Como discutido na Seção 10.2.1, percorrendo o perfil de intensidade da esquerda para a direita, notamos no início da rampa e em certos pontos dele que a primeira derivada é positiva e, nas áreas de intensidade constante, a primeira derivada é igual a zero. **A segunda derivada é positiva no início da rampa, negativa no final dele, zero em certos pontos e novamente zero nos pontos de intensidade constante.** Os sinais das derivadas discutidas



Figura 10.9 Uma imagem 1.508×1.970 que mostra (de forma ampliada) os perfis dos tipos de borda existentes na imagem: uma rampa (em baixo à esquerda), um degrau (no alto à direita), e uma borda em forma de telhado. Os perfis vão do escuro ao claro nas áreas indicadas pelos pequenos segmentos de linha vistos nos pequenos círculos. Os perfis de rampa e de “degrau” cobrem 9 pixels e 2 pixels, respectivamente. A base da borda em forma de telhado é de 3 pixels. (Imagem original: cortesia do dr. David R. Pickens, Universidade de Vanderbilt.)

* Bordas em rampa com uma inclinação acentuada de alguns pixels muitas vezes são tratadas como bordas em degrau, a fim de diferenciá-las das rampas na mesma imagem cujas inclinações são mais gradativas.

anteriormente seriam invertidos para uma borda que vai do claro ao escuro. **A interseção entre o eixo de intensidade zero e uma linha que se estende entre os extremos da segunda derivada cria um ponto chamado cruzamento por zero da segunda derivada.**

Concluimos, a partir dessas observações, que a *magnitude* da primeira derivada pode ser usada para detectar a presença de uma borda em um ponto de uma imagem. Da mesma forma, o *signal* da segunda derivada pode ser usado para determinar se um pixel da borda está do lado escuro ou do lado claro de uma borda. Notamos duas propriedades adicionais da segunda derivada em torno de uma borda: (1) produz dois valores para cada borda em uma imagem (uma característica indesejável); e (2) seus *cruzamentos por zero* podem ser usados para localizar o centro de bordas espessas, como mostraremos mais adiante nesta seção. Alguns modelos de borda fazem uso de uma transição suave no início e no final da rampa (Exercício 10.7). No entanto, as conclusões produzidas por esses modelos são as mesmas de um declive ideal e trabalhar com este último simplifica as formulações teóricas. Finalmente, embora a atenção até agora tenha sido limitada a um perfil horizontal 1-D, argumento similar aplica-se a bordas em quaisquer orientações da imagem. Simplesmente definimos um perfil perpendicular na direção da borda em qualquer ponto desejado e interpretamos os resultados da mesma maneira que ocorre com as bordas verticais já mencionadas.

Exemplo 10.4 Comportamento da primeira e segunda derivadas de uma borda com ruído.

As bordas da Figura 10.8 não apresentam ruído. Os segmentos de imagem na primeira coluna da Figura 10.11 mostram, de forma ampliada, as quatro bordas em declive que fazem a transição de uma região escura à esquerda para uma região branca à direita **(lembre-se de que toda a transição do preto ao branco é uma borda simples)**. O segmento de imagem no canto superior esquerdo não apresenta ruído. As outras três imagens na primeira coluna estão corrompidas por um ruído gaussiano aditivo com média zero e desvio padrão de 0,1, 1,0 e 10,0 níveis de intensidade, respectivamente. O gráfico abaixo de cada imagem é um perfil de intensidade horizontal que passa pelo centro da imagem. Todas as imagens têm resolução de níveis de cinza de 8 bits, com 0 representando o preto e 255 representando o branco.

Considere a imagem na parte superior da coluna central. Conforme discutido no âmbito da Figura 10.10(b), a derivada da linha de varredura da imagem à esquerda é zero nas áreas constantes. Estas são as duas faixas pretas que aparecem na imagem da derivada. As derivadas nos pontos da




Figura 10.10 (a) Duas regiões de intensidade constante, separadas por uma borda vertical em declive ideal. (b) Detalhe próximo à borda, mostrando um perfil de intensidade horizontal, juntamente com o sinal de resposta da primeira e da segunda derivadas.

rampa são constantes e iguais a sua inclinação.* Na imagem da derivada, os valores constantes aparecem em cinza. Conforme descemos pela coluna central, as derivadas ficam cada vez mais diferentes em razão da presença de ruído no sinal original. Na verdade, seria difícil associar o último perfil da coluna central com a primeira derivada de uma borda em declive. O que torna esses resultados interessantes é que o ruído é quase invisível nas imagens na coluna da esquerda. Estes exemplos são perfeitos para ilustrar a sensibilidade das derivadas em relação ao ruído.

Como esperado, a segunda derivada é ainda mais sensível ao ruído. A segunda derivada da imagem sem ruído é apresentada na parte superior da coluna à direita. As linhas finas verticais brancas e pretas são os elementos positivos e negativos da segunda derivada, como explicado na Figura 10.10. O cinza nessas imagens representa o zero (conforme discutido anteriormente, o ajuste na escala de cores faz com que o zero pareça cinza). A única imagem ruidosa de segunda derivada que se assemelha vagamente ao caso sem ruído é aquela correspondente a um ruído com desvio padrão de 0,1. As demais imagens de segundas derivadas e seus respectivos perfis ilustram claramente que seria difícil detectar seus componentes positivos e negativos, que são as características verdadeiramente úteis da segunda derivada em termos de detecção de bordas. O fato de que um pequeno ruído visual possa ter um impacto tão significativo sobre as duas principais derivadas utilizadas para a detecção das bordas é uma questão importante, que deve ser levada em consideração. Em particular, a suavização da imagem deve ser se-

riamente considerada antes de usar derivadas nas aplicações em que ruídos com níveis semelhantes aos que acabamos de discutir possam estar presentes.

Concluimos esta seção observando que existem três passos fundamentais a serem considerados na detecção das bordas:

1. *Suavização da imagem para redução do ruído.* A importância desta etapa é amplamente ilustrada com os resultados da segunda e terceira colunas da Figura 10.11.
2. *Detecção dos pontos de borda.* Como mencionado anteriormente, esta é uma operação local que tira de uma imagem todos os pontos que são candidatos potenciais a se tornarem pontos de borda.
3. *Localização da borda.* O objetivo deste passo é selecionar, dentre os possíveis pontos de borda, apenas aqueles que de fato pertencem ao conjunto de pontos que formam uma borda.

O restante desta seção trata de técnicas para atingir esses objetivos.

10.2.5 Detecção básica de bordas

Como ilustrado na seção anterior, pode-se detectar mudanças na intensidade com a finalidade de encontrar bordas usando as derivadas de primeira ou de segunda ordem. Discutiremos as derivadas de primeira ordem na presente seção e trabalharemos com as derivadas de segunda ordem na Seção 10.2.6.

* Bordas em rampa com inclinação acentuada de alguns pixels são muitas vezes tratadas como bordas em degrau a fim de diferenciá-las das rampas nas mesmas imagens cujas inclinação são mais gradativas.




Figura 10.11 Primeira coluna: imagens e perfis de intensidade de uma borda em declive corrompida pelo ruído gaussiano aleatório de média zero e desvio padrão 0,0, 0,1, 1,0 e 10,0 níveis de intensidade, respectivamente. Segunda coluna: imagens da primeira derivada e seus respectivos perfis de intensidade. Terceira coluna: imagens da segunda derivada e seus respectivos perfis de intensidade.

O gradiente da imagem e suas propriedades

A ferramenta ideal para encontrar a força (intensidade) e a direção da borda na posição (x, y) de uma imagem, f , é o gradiente, denotado por ∇f , e definido como o vetor*

$$\nabla f = \text{grad}(f) = \begin{bmatrix} g_x \\ g_y \end{bmatrix} = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} \quad (10.2-9)$$

Esse vetor tem a importante propriedade geométrica de apontar no sentido da maior taxa de variação de f no local (x, y) .

A magnitude (tamanho) do vetor ∇f , denominado $M(x, y)$, na qual

$$M(x, y) = \text{mag}(\nabla f) = \sqrt{g_x^2 + g_y^2} \quad (10.2-10)$$

é o valor da taxa de variação na direção do vetor gradiente. Nota-se que g_x , g_y e $M(x, y)$ são imagens do mesmo tamanho que a original, criadas quando x e y podem variar ao longo de todas as posições de pixels em f . É comum se

* Por praticidade, repetimos aqui algumas equações da Seção 3.6.4.

referir à última imagem como a *imagem gradiente*, ou simplesmente *gradiente*, quando o significado é claro. A soma, o quadrado, a raiz quadrada e o resto das operações são *operações de arranjo*, conforme definidas na Seção 2.6.1.

A direção do vetor gradiente é dada pelo ângulo

$$\alpha(x, y) = \tan^{-1} \left\{ \frac{g_y}{g_x} \right\} \quad (10.2-11)$$

medido em relação ao eixo x . Como no caso da imagem gradiente, $\alpha(x, y)$ também é uma imagem do mesmo tamanho que a original criada pela divisão do arranjo de g_y pela imagem g_x . A direção de uma borda em um ponto arbitrário (x, y) é ortogonal à direção, $\alpha(x, y)$, do vetor gradiente no ponto.

Exemplo 10.5 Propriedades do gradiente.

A Figura 10.12(a) mostra uma seção ampliada de uma imagem contendo um segmento de borda reto. Cada quadrado corresponde a um pixel e estamos interessados em obter a intensidade e a direção da borda no ponto destacado com uma caixa. Os pixels em cinza têm valor 0 e os pixels brancos têm valor 1. Mostraremos depois deste exemplo que uma abordagem para calcular as derivadas nas direções x e y utilizando uma vizinhança de 3×3 centrada sobre um ponto consiste simplesmente em subtrair o conjunto de pixels localizados na linha superior dessa vizinhança dos pixels localizados na linha inferior, com isso se obtém a derivada parcial na direção x . Da mesma forma, subtraímos os pixels na coluna esquerda dos pixels na coluna da direita para obter a derivada parcial na direção y . Depois, usando essas diferenças como nossas estimativas das derivadas parciais, segue que $\partial f / \partial y = -2$ e $\partial f / \partial x = 2$ no ponto em questão. Então,

$$\nabla f = \begin{bmatrix} g_x \\ g_y \end{bmatrix} = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} = \begin{bmatrix} 2 \\ -2 \end{bmatrix}$$

a partir da qual obtemos $M(x, y) = 2\sqrt{2}$ naquele ponto. Da mesma forma, a direção do vetor gradiente no mesmo ponto




Figura 10.12 Usando o gradiente para determinar a intensidade e a direção da borda em um ponto. Repare que a borda é perpendicular à direção do vetor gradiente no ponto onde o gradiente é computado. Cada quadrado na figura representa um pixel.

é produto da Equação 10.2-11: $\alpha(x, y) = \tan^{-1}(g_y/g_x) = -45^\circ$, que é o mesmo que 135° medido no sentido positivo em relação ao eixo x . A Figura 10.12(b) mostra o vetor gradiente e o ângulo de sua direção.

A Figura 10.12(c) ilustra o importante fato, mencionado anteriormente, de que a borda em um ponto é ortogonal ao sentido do vetor gradiente naquele ponto. Assim, o ângulo de direção da borda neste exemplo é $\alpha - 90^\circ = 45^\circ$. Todos os pontos de borda na Figura 10.12(a) têm o mesmo gradiente, então todo o segmento de borda está na mesma direção. O vetor gradiente às vezes é chamado de *vetor normal da borda*. Quando o vetor é normalizado para o comprimento da unidade, dividindo-o por sua magnitude (Equação 10.2-10), o vetor resultante é comumente chamado de *vetor normal unitário da borda*.

Operadores de gradiente

A obtenção do gradiente de uma imagem requer o cálculo das derivadas parciais $\partial f / \partial x$ e $\partial f / \partial y$ em qualquer posição da imagem. Estamos lidando com quantidades digitais; por isso, uma aproximação digital das derivadas parciais em uma vizinhança sobre um ponto é necessária. Da Seção 10.2.1, sabemos que

$$g_x = \frac{\partial f(x, y)}{\partial x} = f(x + 1, y) - f(x, y) \quad (10.2-12)$$

e

$$g_y = \frac{\partial f(x, y)}{\partial y} = f(x, y + 1) - f(x, y) \quad (10.2-13)$$

Essas duas equações podem ser implementadas para todos os valores pertinentes x e y , filtrando $f(x, y)$ com as máscaras 1-D na Figura 10.13.

Quando o objeto de interesse trata-se de uma borda inclinada (direção diagonal), precisamos de uma máscara 2-D. Os *operadores de gradiente cruzado de Roberts* [Roberts (1965)] são uma das primeiras tentativas de usar máscaras 2-D com preferência na diagonal. Considere a região 3×3 na Figura 10.14(a). Os operadores de Roberts estão baseados na implementação de diferenças diagonais*

* No restante desta seção, assumimos implicitamente que f é dada em função de duas variáveis e omitimos as variáveis para simplificar a notação.




Figura 10.13 Máscaras unidimensionais utilizadas para implementar as equações 10.2-12 e 10.2-13.

$$g_x = \frac{\partial f}{\partial x} = (z_9 - z_5) \quad (10.2-14)$$

e

$$g_y = \frac{\partial f}{\partial y} = (z_8 - z_6) \quad (10.2-15)$$

Essas derivadas podem ser implementadas filtrando uma imagem com as máscaras apresentadas nas figuras 10.14(b) e (c).

As máscaras de tamanho 2×2 são simples conceitualmente, mas não são tão úteis para calcular a direção da borda quanto as máscaras que são simétricas ao redor do ponto central, das quais as menores são de tamanho 3×3 . Essas máscaras levam em consideração a natureza dos dados nos lados opostos do ponto central e, assim, carregam mais informações a respeito da direção de uma borda. As aproximações digitais mais simples para as derivadas parciais usando máscaras de tamanho 3×3 são dadas por*

$$g_x = \frac{\partial f}{\partial x} = (z_7 + z_8 + z_9) - (z_1 + z_2 + z_3) \quad (10.2-16)$$

e

$$g_y = \frac{\partial f}{\partial y} = (z_3 + z_6 + z_9) - (z_1 + z_4 + z_7) \quad (10.2-17)$$

Nestas formulações, a diferença entre a terceira e a primeira linha da região 3×3 aproxima a derivada na direção do eixo x , e a diferença entre a terceira e a primeira coluna aproxima a derivada na direção de y . Intuitivamente, esperaríamos que essas aproximações fossem mais precisas do que as aproximações obtidas utilizando os operadores de Roberts. As equações 10.2-16 e 10.2-17 podem ser executadas ao longo de uma imagem inteira, filtrando f com as duas máscaras nas figuras 10.14(d) e (e). Estas máscaras recebem o nome de *operadores de Prewitt* [Prewitt (1970)].

Uma ligeira variação das últimas duas equações utiliza o valor 2 como peso no centro do coeficiente:

* Embora essas equações abranjam uma vizinhança maior, ainda estamos lidando com as diferenças entre os valores de intensidade; por isso, as conclusões das discussões anteriores sobre as derivadas de primeira ordem ainda se aplicam.




Figura 10.14 Uma região 3×3 de uma imagem (os z s são valores de intensidade) e várias máscaras usadas para calcular o gradiente no ponto z_5 **

$$g_x = \frac{\partial f}{\partial x} = (z_7 + 2z_8 + z_9) - (z_1 + 2z_2 + z_3) \quad (10.2-18)$$

e

$$g_y = \frac{\partial f}{\partial y} = (z_3 + 2z_6 + z_9) - (z_1 + 2z_4 + z_7) \quad (10.2-19)$$

Pode ser demonstrado (Exercício 10.10) que a utilização do valor 2 na posição central produz a suavização da imagem. As figuras 10.14(f) e (g) mostram as máscaras utilizadas para implementar as equações 10.2-18 e 10.2-19. Essas máscaras são chamadas de *operadores de Sobel* [Sobel (1970)].

As máscaras de Prewitt são mais simples de implementar do que as máscaras de Sobel, mas a ligeira diferença

** As máscaras de filtro usadas para calcular as derivadas necessárias para o gradiente são frequentemente chamadas de *operadores de gradiente*, *operadores de diferença*, *operadores de borda* ou *detectores de borda*.

de cálculo entre elas normalmente não é um problema. O fato de as máscaras de Sobel apresentarem melhor supressão de ruído (suavização) faz com que sejam preferíveis, porque, como mencionado na seção anterior, a supressão do ruído é uma questão importante quando se lida com derivadas. Note que os coeficientes de todas as máscaras na Figura 10.14 somam zero, dando, assim, uma resposta nula nas áreas de intensidade constante, como esperado para um operador derivativo.

As máscaras que acabamos de discutir são utilizadas para obter os componentes de gradiente g_x e g_y em cada endereço de pixel da imagem. Essas duas derivadas parciais são, então, utilizadas para estimar a intensidade e a direção da borda. Calcular a magnitude do gradiente exige que g_x e g_y sejam combinados da maneira descrita pela Equação 10.2-10. No entanto, essa aplicação nem sempre é desejável em razão do custo computacional exigido pelos quadrados e pelas raízes quadradas. Uma abordagem usada frequentemente é aproximar a magnitude do gradiente usando valores absolutos:

$$M(x, y) \approx |g_x| + |g_y| \quad (10.2-20)$$

Essa equação é computacionalmente mais atraente e ainda preserva mudanças relativas nos níveis de intensidade. O preço pago por essa vantagem é que os filtros resultantes não serão isotrópicos (invariantes à rotação) em geral. No entanto, este não é um problema quando máscaras como as de Sobel e de Prewitt são usadas para computar g_x e g_y porque essas máscaras dão resultados isotrópicos apenas para bordas verticais e horizontais. Os resultados seriam isotrópicos apenas para bordas nessas duas direções, independentemente de qual das duas equações for utilizada. Além disso, as equações 10.2-10 e 10.2-20 produzem resultados idênticos para as bordas verticais e horizontais quando as máscaras de Sobel ou de Prewitt são usadas (Exercício 10.8).

É possível modificar as máscaras 3×3 na Figura 10.14 para que suas respostas tenham mais intensidades ao longo das direções diagonais. A Figura 10.15 mostra as duas máscaras adicionais de Prewitt e de Sobel necessárias para a detecção de bordas nas direções diagonais.

Exemplo 10.6 Ilustração da magnitude e do ângulo (direção) do gradiente 2-D.

A Figura 10.16 ilustra a resposta do valor absoluto dos dois componentes do gradiente, $|g_x|$ e $|g_y|$, bem como a imagem do gradiente formada a partir da soma desses dois componentes. A direcionalidade dos componentes horizontais e verticais do gradiente é evidente nas figuras 10.16(b) e (c). Observe, por exemplo, quão forte é a telha, as juntas dos tijolos horizontais e os segmentos horizontais das janelas na

a	Prewitt			b		
0	1	1	-1	-1	0	
-1	0	1	-1	0	1	
-1	-1	0	0	1	1	

c	Prewitt			d		
0	1	2	-2	-1	0	
-1	0	1	-1	0	1	
-2	-1	0	0	1	2	

Sobel

Figura 10.15 Máscaras de Prewitt e de Sobel para a detecção de bordas diagonais.

Figura 10.16(b) em relação às outras bordas. Em contrapartida, a Figura 10.16(c) favorece as características dos componentes verticais da fachada e das janelas. É comum usar o termo *mapa de bordas* quando falamos de uma imagem cujas características principais são as bordas, como as imagens de magnitude do gradiente. A intensidade da imagem na Figura 10.16(a) foi ajustada para o intervalo [0, 1]. Utilizamos valores nesse intervalo para simplificar a seleção de parâmetros nos diversos métodos para a detecção de bordas discutidos nesta seção.




Figura 10.16 (a) Imagem original com tamanho 834×1.114 pixels com valores de intensidade ajustados para o intervalo [0, 1]. (b) $|g_x|$, o componente do gradiente na direção x , obtido utilizando a máscara de Sobel na Figura 10.14(f) para filtrar a imagem. (c) $|g_y|$, obtida utilizando a máscara da Figura 10.14(g). (d) Imagem de gradiente, $|g_x| + |g_y|$.